MINISTERE DE L'ENSEIGNMEMENT SUPERIEUR
ET DE LA RECHERCHE SCIENTIFIQUE

UNIVERSITE FELIX HOUPHOUET BOIGNY

DATA SCIENCE
INTELLIGENCE ARTIFICIELLE

UFR MATHEMATIQUE ET INFORMATIQUE

MODELISATION ET PREDICTION DE L'OCCUPATION DES SOLS PAR RESEAU DE NEURONES ARTIFICIELS (ANN)

LES ETUDIANTS :

ASSAMOI ARMIDA YASSINE

YAHIRI BOH DANIEL

PROFESSEUR :

Dr AYIKPA KACOUTCHY JEAN

💻 **Application de démonstration en ligne :** https://occupation-sols-yakro.streamlit.app/

SOMMAIRE

INTRODUCTION

CHAPITRE I : DONNÉES, NETTOYAGE ET ANALYSE EXPLORATOIRE

CHAPITRE II : MÉTHODOLOGIE ET EXPÉRIENCES

II.1 La méthodologie

II.2 Les expériences

CHAPITRE III : COMPARAISON AVEC LES MODÈLES CLASSIQUES

III.1 Protocole commun

III.2 Les modèles

III.2.1 Random Forest

III.2.2 SVM

III.2.3 XGBoost

III.3 Comparaison des modèles

III.4 Modèle final : interprétation (SHAP) et analyse des erreurs

III.5 Évaluation finale sur l'ensemble de test

CONCLUSION FINALE

LIMITES

PERSPECTIVES

RÉFÉRENCES

INTRODUCTION

1.1. Contexte et problématique

La cartographie de l'occupation des sols constitue un outil essentiel pour la gestion durable des ressources naturelles, le suivi des écosystèmes, le développement agricole et l'aménagement du territoire. Elle permet d'identifier et de suivre la répartition des différentes catégories de couverture terrestre, telles que les formations forestières, les zones agricoles, les plans d'eau, les zones humides et les espaces urbanisés. Dans ce contexte, la télédétection satellitaire représente une source d'information particulièrement intéressante.

Cependant, la classification de ces données demeure un défi en raison de la diversité des signatures spectrales, de la similarité entre certaines classes, et du déséquilibre entre les catégories représentées dans les jeux de données. Face à ces difficultés, les méthodes d'apprentissage automatique et, plus particulièrement, les approches fondées sur le Deep Learning offrent des possibilités intéressantes pour améliorer la classification. Parmi elles, les réseaux de neurones artificiels (Artificial Neural Networks ou ANN) sont capables d'apprendre des relations complexes et non linéaires entre les variables spectrales et les catégories d'occupation des sols.

C'est dans cette perspective que s'inscrit ce travail, qui porte sur l'utilisation des réseaux de neurones artificiels pour la classification de l'occupation des sols dans la région de Yamoussoukro. Il vise à étudier l'influence de plusieurs choix méthodologiques, notamment la profondeur des architectures, les optimiseurs, les fonctions d'activation, les fonctions de perte et les techniques de régularisation, sur les performances et la capacité de généralisation des modèles.

La question centrale de cette étude est donc la suivante : **dans quelle mesure les choix architecturaux et les stratégies d'apprentissage influencent-ils les performances et la capacité de généralisation des réseaux de neurones artificiels pour la classification de l'occupation des sols à partir de données spectrales ?**

Cette problématique se décline en plusieurs questions de recherche :

- Une architecture plus profonde permet-elle systématiquement d'obtenir de meilleures performances qu'un réseau peu profond ?

- Quel optimiseur offre le meilleur compromis entre qualité de classification, vitesse de convergence et stabilité de l'apprentissage ?
- Dans quelle mesure les fonctions d'activation, les fonctions de perte et les techniques de régularisation influencent-elles les résultats ?
- La prise en compte du déséquilibre des classes améliore-t-elle la reconnaissance des catégories minoritaires ?
- Comment les performances des ANN se comparent-elles à celles des méthodes classiques d'apprentissage automatique, notamment Random Forest, SVM et XGBoost ?

1.2. Démarche générale du travail

Pour répondre à ces questions, une démarche expérimentale progressive a été adoptée. Elle commence par une analyse exploratoire des données afin d'examiner leur structure. Cette première étape est suivie de la préparation des données et de la définition d'un protocole expérimental commun destiné à assurer la cohérence des comparaisons entre les modèles.

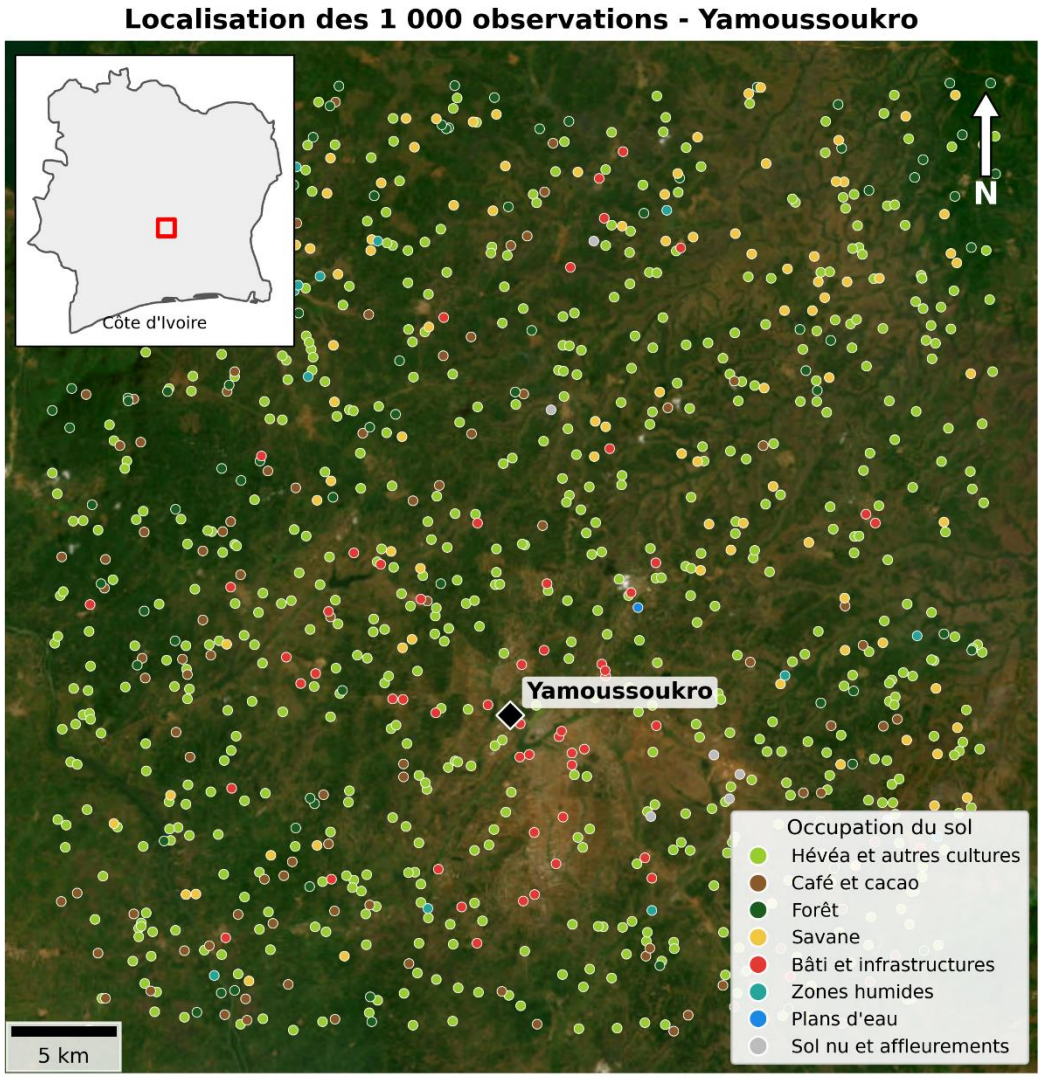
Plusieurs expériences sont ensuite conduites afin d'évaluer l'influence des différentes configurations des réseaux de neurones artificiels sur leurs performances. Enfin, les performances des ANN sont mises en perspective avec celles de modèles classiques d'apprentissage automatique, tels que Random Forest, SVM et XGBoost.

Le présent rapport s'organise en trois chapitres. Le premier chapitre présente la zone d'étude et les données, puis décrit leur nettoyage et leur analyse exploratoire : répartition des classes, dépendance spatiale, redondance des variables et signatures spectrales. Le deuxième chapitre expose le protocole expérimental et les six expériences menées sur le réseau de neurones (architecture, optimiseur, activation, régularisation, déséquilibre des classes, familles de variables), complétées par une sélection automatique des variables et une validation spatiale. Le troisième chapitre compare le réseau retenu à trois modèles classiques (Random Forest, SVM, XGBoost), interprète le modèle final et l'évalue sur l'ensemble de test. Une conclusion fait la synthèse des résultats, puis présente les limites du travail et des perspectives.

CHAPITRE 1 : DONNEES, NETTOYAGE, ET ANALYSE EXPLORATOIRE

1. Zone d'étude

Les observations couvrent un carré d'environ **45 × 45 km centré sur Yamoussoukro**, capitale politique de la Côte d'Ivoire, entre 6,69° et 7,10° de latitude nord et entre 5,49° et 5,08° de longitude ouest. La région se situe dans la zone de transition entre la forêt dense humide du sud et les savanes du centre du pays (le « V Baoulé »). Le paysage y est une mosaïque de cultures de rente (hévéa, café, cacao), de cultures vivrières, de reliques forestières, de savanes et de zones urbaines, traversée par le fleuve Bandama et ponctuée de retenues d'eau, dont le lac visible au nord-ouest de la zone.



Sources : Data_Yakro (Sentinel-2) ; fond Esri World Imagery ; EPSG:32630

2. Les données

Le fichier Data_Yakro_New.csv contient **1 000 observations ponctuelles et 25 colonnes**. Chaque ligne correspond à un point géolocalisé auquel sont associées une classe d'occupation du sol et des valeurs spectrales extraites d'une image satellite. Le tableau ci-dessous précise le rôle de chaque variable dans l'étude.

Tableau 1 : Description des variables

Variable	Type	Description	Rôle
Id	Entier	Identifiant unique de l'observation (0 à 999)	Traçabilité, exclu des prédicteurs
Classes1	Entier (1 à 8)	Code numérique de la classe	Cible (forme codée)
Class_name	Texte	Libellé de la classe	Cible (forme lisible)
Geometry	Texte (WKT)	Point « POINT (x y) » en mètres	Localisation, analyse spatiale
B1 à B10	Réel	Réflectances de surface dans 10 bandes	Prédicteurs
NDVI, EVI, NDRE, SAVI, NDMI, NDWI, NDWI2, MSI, NDBI, BSI, BI	Réel	Indices spectraux calculés à partir des bandes	Prédicteurs (après sélection)

3. Contrôle qualité et nettoyage des données

3.1.Intégrité des données

Les contrôles réalisés sont résumés dans le tableau. Aucun ne révèle d'anomalie : le fichier est complet, sans doublon, et toutes les valeurs sont physiquement possibles.

Tableau 2 : Contrôles de qualité réalisés

Contrôle	Résultat
Valeurs manquantes	0
Valeurs infinies	0
Lignes dupliquées	0
Observations aux coordonnées identiques	0
Réflectances hors de l'intervalle [0, 1]	0
Indices normalisés hors de l'intervalle [−1, 1]	0
Correspondance un à un entre Classes1 et class_name	Parfaite (8 codes, 8 libellés)

3.2. Préparation des variables

La préparation des données a d'abord consisté à convertir la colonne geometry, initialement stockée sous forme de texte, en objets géométriques à l'aide de Shapely, puis en GeoDataFrame avec GeoPandas, en utilisant le système de coordonnées EPSG :32630. Les coordonnées spatiales (x, y), ainsi que la latitude et la longitude, ont ensuite été extraites.

La variable class_name a été convertie en variable catégorielle pour servir de cible à la classification. Les colonnes Classes1 et class_name contenant la même information, une seule a été retenue pour la modélisation.

L'analyse des redondances a conduit à supprimer les indices NDWI2 et NDBI, respectivement identiques à NDMI et à son opposé. Le jeu de données conserve ainsi 19 variables explicatives, composées de bandes spectrales et d'indices. Le MSI a toutefois été maintenu afin d'évaluer son utilité lors de la modélisation.

Enfin, les valeurs atypiques et les incohérences éventuelles des étiquettes ont fait l'objet d'un traitement spécifique. Le jeu de données préparé a été exporté dans le fichier donnees_propres.csv, comprenant 1 000 observations et 28 colonnes. Les étiquettes initiales, les étiquettes corrigées et le journal des modifications ont été conservés afin d'assurer la traçabilité des traitements effectués.

4. Visualisation des données

4.1.Répartition des classes

Les 1 000 observations se répartissent en huit classes très inégalement représentées. Rubber and Other Crops domine avec 601 observations (60,1 %), suivie de Savannas et Coffee and Cocoa (101 chacune, 10,1 %). À l'autre extrémité, Wetlands (2,6 %), Water Bodies (2,5 %) et Bare Soil and Rock Outcrops (8 observations, 0,8 %) sont très minoritaires. Le rapport entre la plus grande et la plus petite classe atteint 75 pour 1.

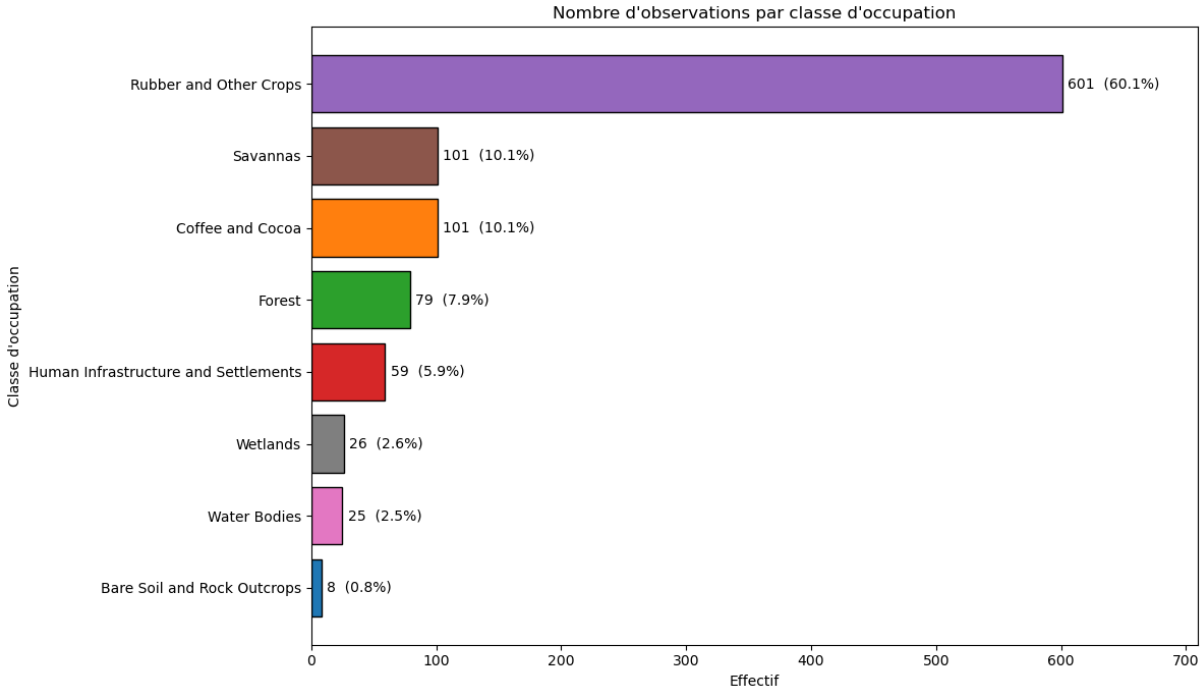


Figure 1 : Nombre d'observations par classe d'occupation

Ce déséquilibre a deux conséquences. D'abord, un modèle qui prédirait toujours la classe majoritaire obtiendrait déjà 60 % d'accuracy : cette métrique seule est donc trompeuse.

4.2. Répartition spatiale des observations

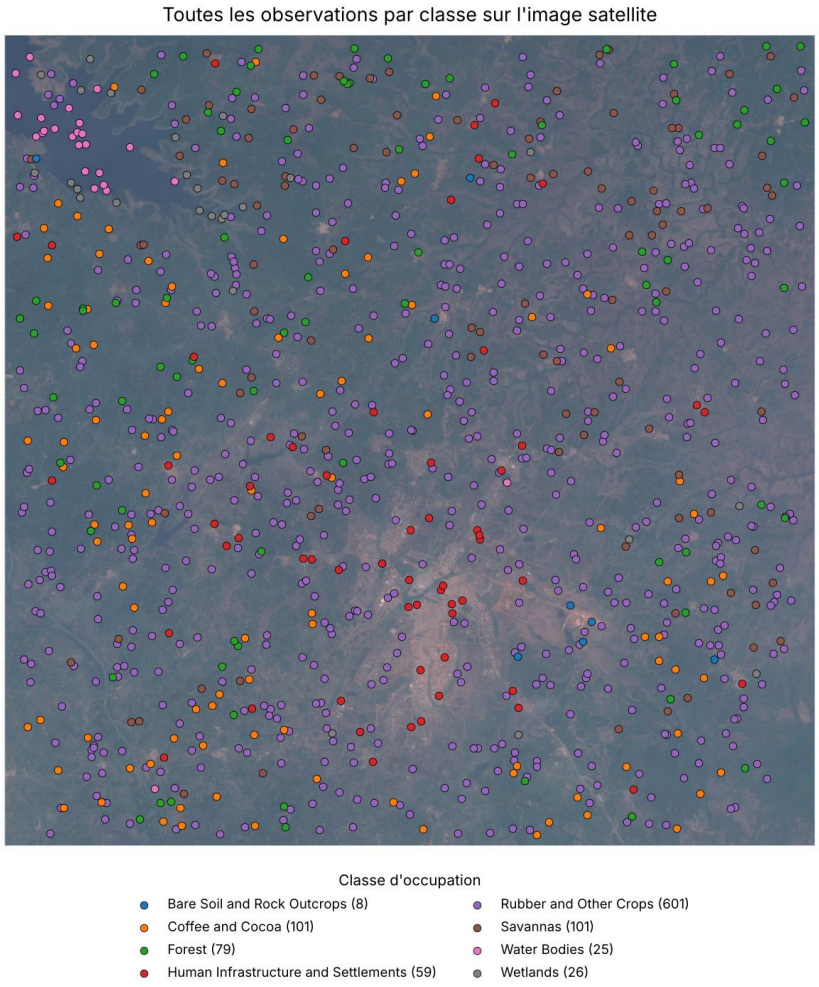


Figure 2 : Répartition des données

Le zoom par classe confirme globalement la répartition spatiale observée. La classe majoritaire « Rubber and Other Crops », qui regroupe plusieurs cultures, est dispersée sur l'ensemble de la zone. Les autres classes se concentrent globalement dans les secteurs attendus : les plans d'eau et zones humides autour du lac au nord-ouest, les zones bâties et les sols nus à l'est, tandis que Forest, Coffee and Cocoa et Savannas présentent des regroupements par secteur.

Deux observations classées « Water Bodies » se situent toutefois en terre ferme, loin du lac, ce qui mérite d'être vérifié. Par ailleurs, certaines observations de « Human Infrastructure » se trouvent en milieu boisé, près des cours d'eau et des plantations. Cette répartition pourrait traduire une proximité recherchée entre les habitations, les ressources en eau et les terres cultivables.

4.3. Mesurer le regroupement spatial

Pour quantifier ce regroupement, nous avons réalisé un test de permutation : pour chaque point, on calcule la part de ses cinq plus proches voisins géographiques qui appartiennent à la même classe, puis on compare cette valeur à celle obtenue en mélangeant aléatoirement les étiquettes 999 fois. Globalement, 46,9 % des voisins appartiennent à la même classe, contre 39,3 % attendus au hasard ; aucune des 999 permutations n'atteint la valeur observée (maximum de 42,2 %, z = 11,2, p = 0,001).

Classe	Observé	Attendu au hasard	Rapport Observé/hasard	p corrigée (Bonferroni)
Water Bodies	0,640	0,025	25,4	0,008
Bare Soil and Rock Outcrops	0,100	0,006	17,8	0,024
Wetlands	0,223	0,025	8,8	0,008
Human Infrastructure and Settlements	0,224	0,059	3,8	0,008
Forest	0,172	0,078	2,2	0,008
Coffee and Cocoa	0,168	0,101	1,7	0,008
Savannas	0,166	0,101	1,6	0,024
Rubber and Other Crops	0,641	0,602	1,1	0,008

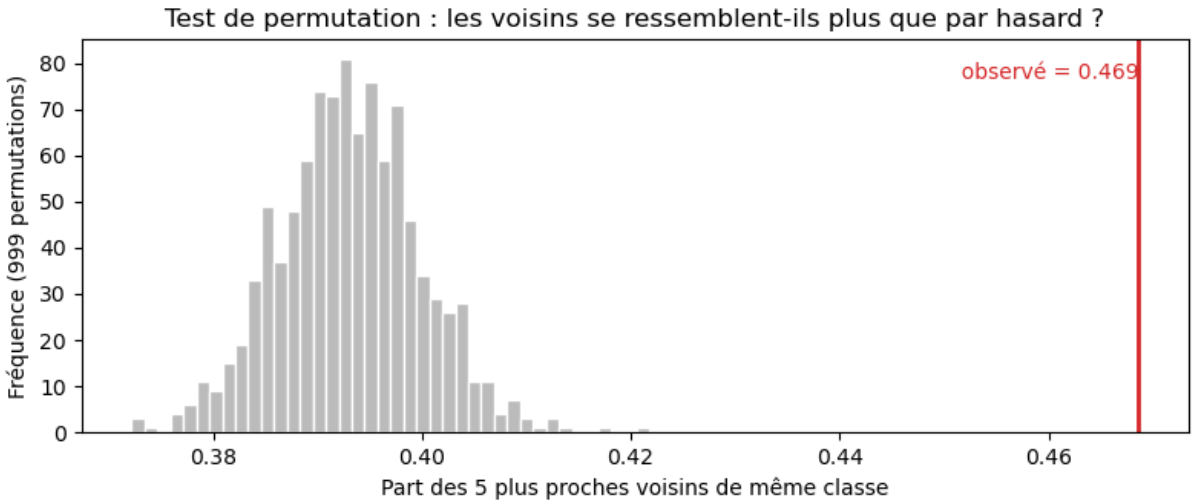


Figure 3 : Test de permutation

Toutes les classes sont significativement regroupées, même après correction pour les huit tests simultanés. L'intensité du regroupement varie toutefois fortement : très forte pour l'eau, les zones humides et le bâti, modérée pour les classes végétales, faible pour Rubber, présente partout.

Ce résultat est cohérent avec les cartes. Les forêts sont concentrées dans certains secteurs (le nord) sans former de massifs continus. Pour décrire à quelle distance cette ressemblance s'éteint, nous utilisons le variogramme.

4.4. Portée de la dépendance spatiale : le variogramme

Le variogramme mesure, pour chaque distance h, la dissemblance moyenne entre deux points séparés de h (Matheron, 1963). Calculé sur les variables standardisées, il atteint 1 lorsque deux points ne se ressemblent pas plus que deux points pris au hasard.

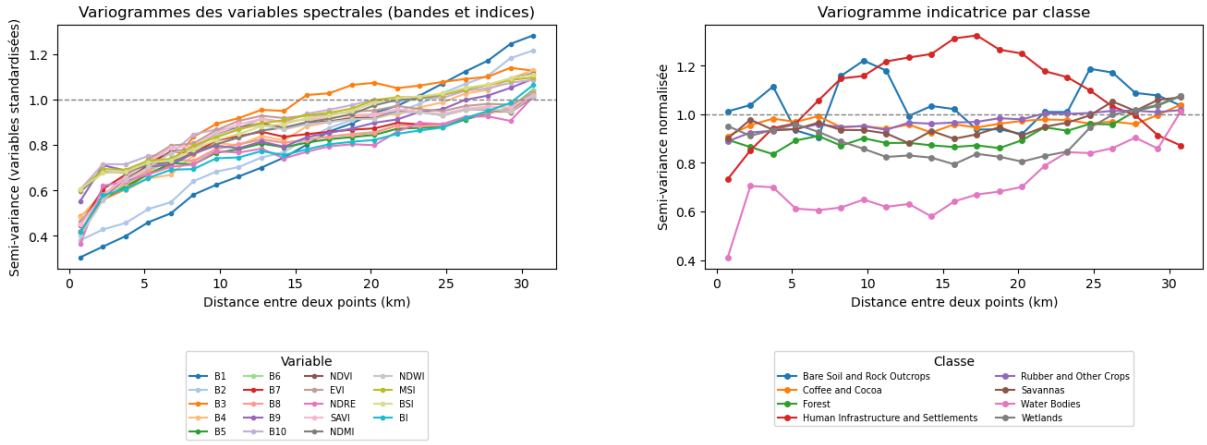


Figure 4 : Variogrammes des 19 variables spectrales (à gauche) et des classes (à droite).

L'analyse révèle que les différences entre observations restent importantes, même à courte distance, traduisant un paysage en mosaïque. Les variables se regroupent en trois familles : les bandes bleues et aérosols, les variables de végétation et celles liées à l'humidité, conformément aux résultats de l'ACP.

La ressemblance spatiale s'atténue vers 15 à 25 km. Cette dépendance confirme la première loi de la géographie (Tobler, 1970) : les points proches se ressemblent davantage. Ainsi, une séparation aléatoire entre entraînement et test peut surestimer les performances sur une zone géographique nouvelle (Roberts et al., 2017).

5. Valeurs atypiques

Une valeur atypique peut avoir trois origines, qui appellent trois décisions différentes : une erreur de mesure (corriger ou supprimer), un point réel mais rare (conserver, car le modèle doit l'apprendre) ou une erreur d'étiquette (vérifier).

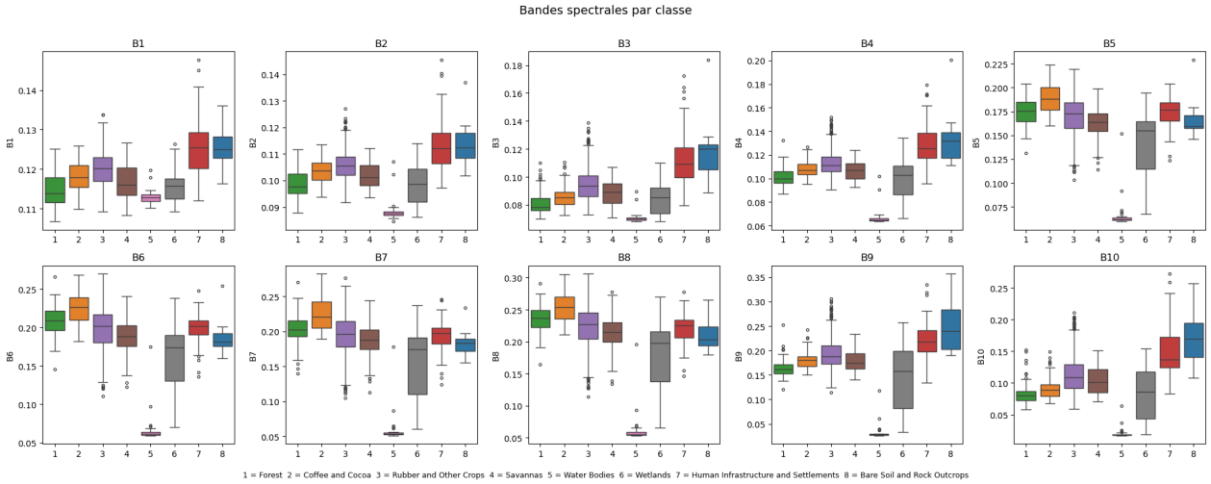


Figure 5 : Boîte à moustache des bandes spectrales par classe

Les boîtes à moustaches confirment les signatures spectrales attendues : le bâti et le sol nu présentent les réflectances les plus élevées, tandis que les classes végétalisées dominent dans le red edge et le PIR. Water Bodies est la classe la plus homogène, contrairement à Wetlands, plus dispersée en raison de la diversité de ses surfaces.

La plupart des valeurs atypiques correspondent à des situations réelles et ont donc été conservées. Elles concernent notamment des pixels mixtes en périphérie de la ville, des parcelles humides, des surfaces bâties particulières et des points d'eau situés en bordure du lac.

Trois cas douteux ont été vérifiés sur image satellite haute résolution (Google Maps), après conversion des coordonnées en latitude et longitude :

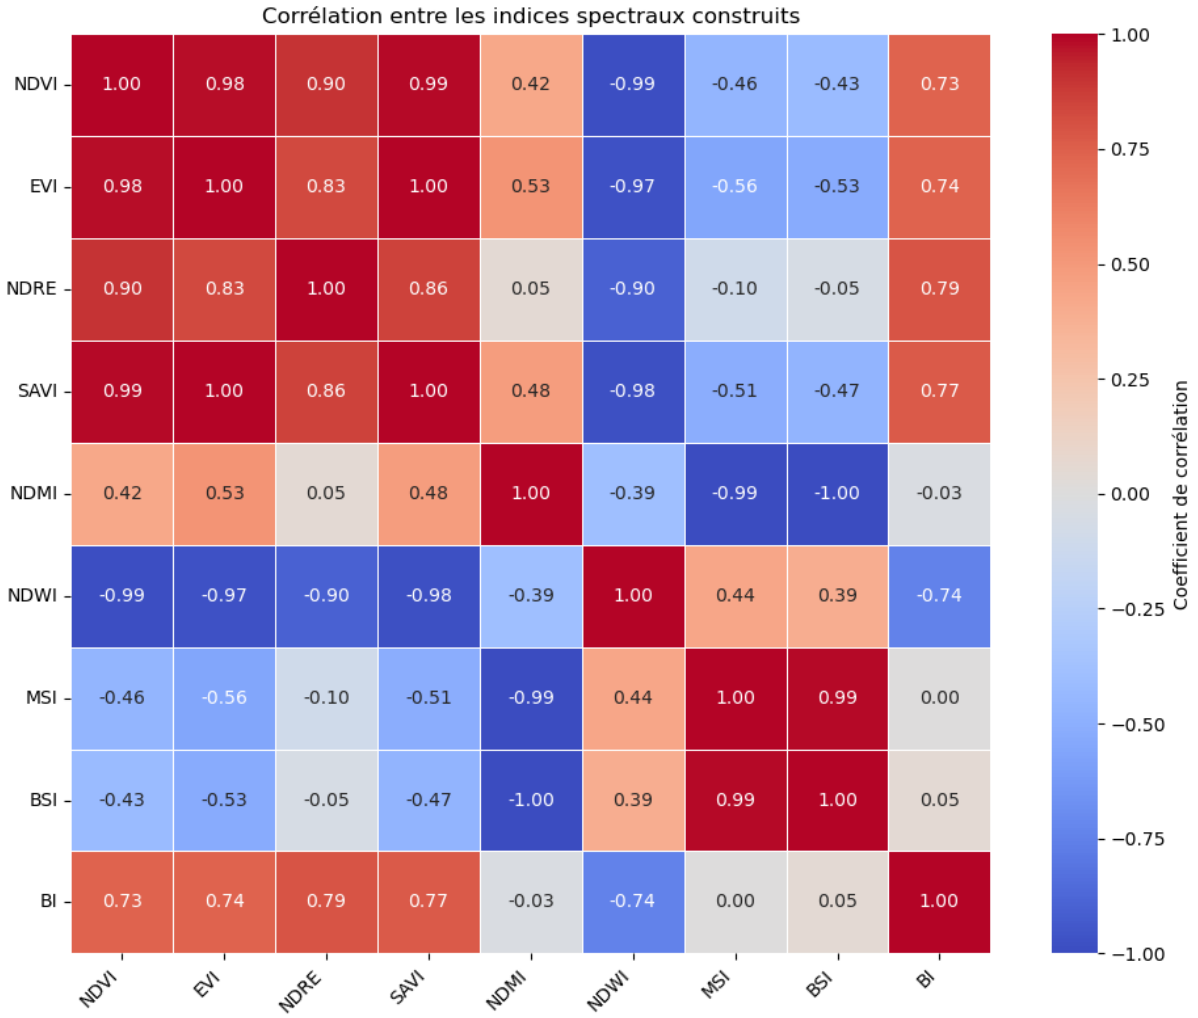
id	Étiquette d'origine	Constat sur l'image et le spectre	Décision
193	Water Bodies	Berge boisée du Bandama, en bordure immédiate du fleuve. Spectre de végétation très humide (NDVI = 0,32, SWIR plus bas que toutes les classes végétalisées), au centre du profil Wetlands	Ré-étiquetée Wetlands
584	Water Bodies	Au milieu d'un lac près de l'INP-HB Sud : c'est bien de l'eau	Conservée
732	Forest	Savane arbustive en bordure d'un massif forestier ; SWIR élevé et NDVI faible (0,18)	Ré-étiquetée Savannas

Deux étiquettes ont ainsi été corrigées. Les effectifs passent de 25 à 24 pour Water Bodies, de 26 à 27 pour Wetlands, de 79 à 78 pour Forest et de 101 à 102 pour Savannas. Les étiquettes d'origine sont conservées dans le fichier final et dans un journal des corrections.

Ces corrections appellent deux précautions. D'une part, l'image consultée n'a pas la même date que les données : un changement d'occupation entre les deux dates ne peut pas être exclu, et les décisions retenues sont celles qui restent cohérentes à la fois avec l'image et avec le spectre.

6. Redondance des variables : corrélations et ACP

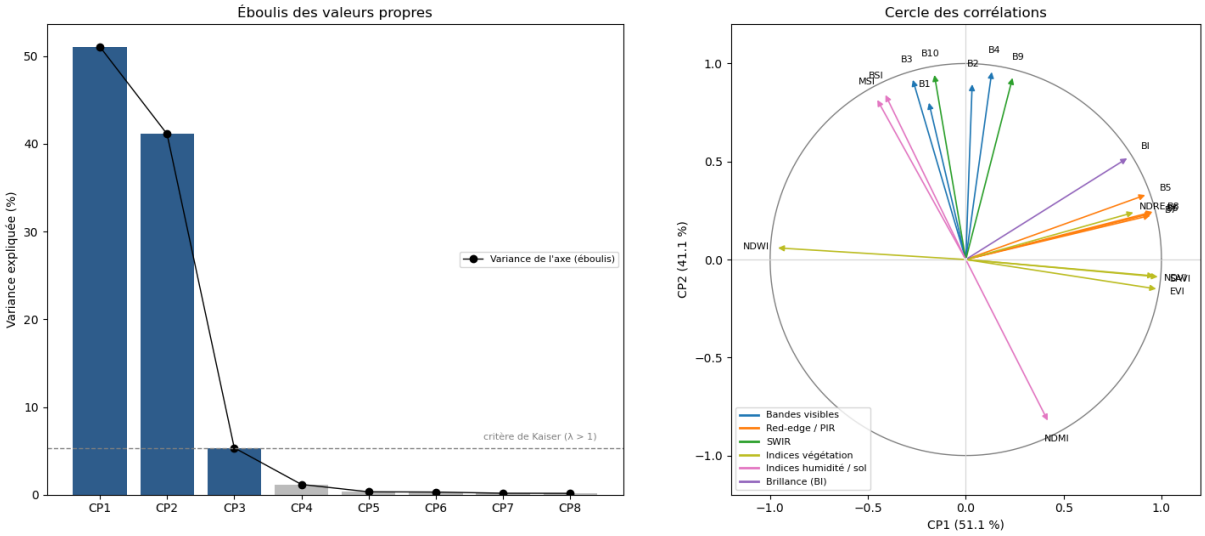
6.1. Corrélations entre indice



La matrice révèle de fortes corrélations entre certains indices, notamment NDVI, EVI et SAVI (0,98 à 1,00), qui apportent des informations similaires sur la végétation. Le NDMI présente également de fortes corrélations négatives avec le MSI (−0,99) et le BSI (−1,00). À l'inverse, sa corrélation avec le NDRE est faible (0,05), suggérant des informations complémentaires. Ces résultats permettront d'identifier les variables redondantes et de guider leur sélection pour la modélisation.

6.2. Analyse en composante principale

La matrice de corrélation montre des paires redondantes, mais elle ne dit pas combien d'informations indépendantes contiennent les 19 variables. L'analyse en composantes principales (ACP) répond à cette question en résumant les variables standardisées par un petit nombre d'axes non corrélés.



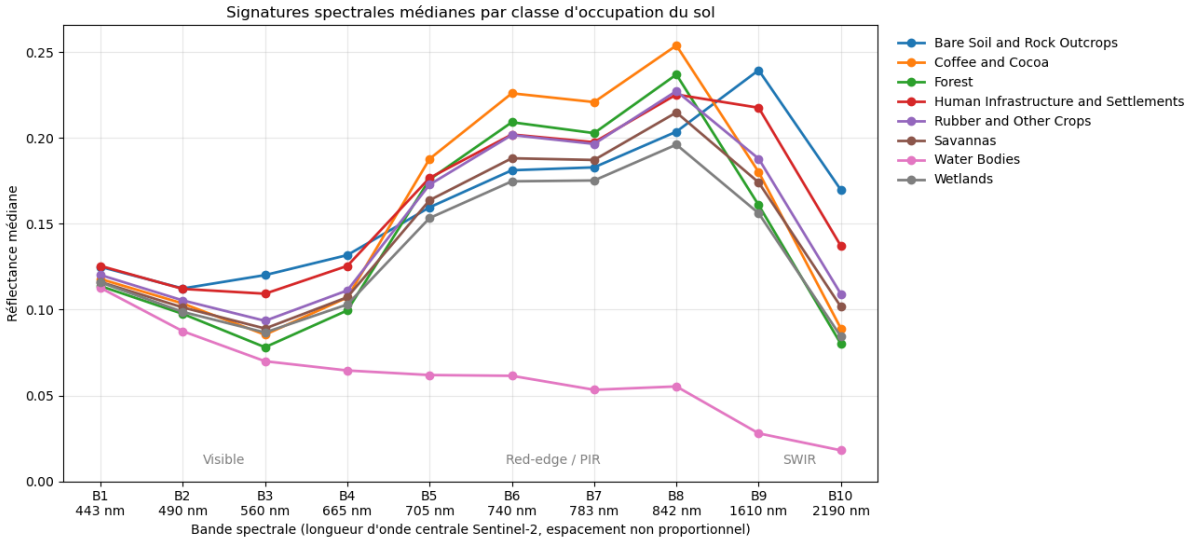
Deux axes résument 92,2 % de l'information des 19 variables (51,1 % et 41,1 %), et trois axes 97,6 %. Seuls les deux premiers ont une valeur propre nettement supérieure à 1 (9,71 et 7,82) ; le troisième est à la limite du critère de Kaiser (1,02). Autrement dit, les 19 variables décrivent essentiellement deux dimensions physiques :

- CP1, la vigueur végétale. Cet axe est porté par les bandes du red edge et du PIR (B5 à B8) et par les indices de végétation (NDVI, EVI, SAVI, NDRE), avec le NDWI à l'opposé. Il oppose les couverts denses à l'eau.
- CP2, la brillance et la sécheresse de la surface. Il est porté par les bandes visibles (B1 à B4), l'infrarouge moyen (B9, B10), le MSI et le BSI, avec le NDMI à l'opposé. Il oppose les surfaces claires et sèches (bâti, sol nu) aux surfaces humides.

Les deux groupes de flèches sont presque perpendiculaires : savoir qu'un point est très végétalisé ne dit presque rien de la brillance de sa surface, et inversement. La projection des observations sur ce plan (figure 1.8) dessine un triangle de mélange spectral, classique en télédétection : végétation dense d'un côté, sols nus et bâti au sommet, eau à l'opposé. Chaque pixel est un mélange de ces trois pôles.

7. Signatures spectrales des classes

La signature spectrale est la courbe de réflectance d'une surface selon la longueur d'onde. La médiane de chaque classe a été tracée, car elle est robuste aux valeurs atypiques.



Water Bodies présente une signature distincte, avec une réflectance presque nulle dans l'infrarouge. Human Infrastructure et Bare Soil ont des profils proches, marqués par de fortes réflectances dans le rouge et le SWIR. Les cinq classes végétalisées partagent également une signature similaire, avec des différences de hauteur dans le PIR et le SWIR. Ces ressemblances spectrales peuvent compliquer la distinction entre certaines classes lors de la classification.

CHAPITRE II : METHODOLOGIE ET EXPERIENCES

I. LA METHODOLOGIE

Toutes les expériences suivent un même protocole : une partition fixe des données (70 / 15 / 15), cinq initialisations des poids par configuration et **un seul facteur modifié à la fois**. La configuration retenue à l'issue d'une expérience devient la référence de la suivante. Ce chapitre décrit la préparation des données, le modèle de base, les règles d'entraînement et les critères de comparaison.

1. Préparation des données

Le modèle reçoit les 19 variables explicatives retenues au chapitre 1 : les 10 bandes B1 à B10 et les 9 indices NDVI, EVI, NDRE, SAVI, NDMI, NDWI, MSI, BSI et BI. L'identifiant et les coordonnées géographiques ne sont pas utilisés comme prédicteurs.

Les 1 000 observations sont réparties de manière stratifiée en trois ensembles : entraînement (700), validation (150) et test (150). Le découpage, effectué avec une graine fixe, est conservé pour garantir une comparaison équitable entre les expériences.

Classe	Entraînement	Validation	Test
Rubber and Other Crops	421	90	90
Savannas	71	15	16
Coffee and Cocoa	71	15	15
Forest	55	12	11
Human Infrastructure and Settlements	41	9	9
Wetlands	19	4	4
Water Bodies	17	4	3
Bare Soil and Rock Outcrops	5	1	2
Total	**700**	**150**	**150**

Ce tableau montre une limite importante. Plusieurs classes n’ont que 1 à 4 observations en validation. Pour elles, une seule observation bien ou mal classée change fortement le score. Nous en tiendrons compte dans toutes les interprétations.

Les variables sont ensuite standardisées : on retire la moyenne et on divise par l'écart-type. Cette étape est indispensable, car les variables ont des échelles très différentes. Les moyennes et écarts-types sont calculés sur l'entraînement seulement, puis appliqués à la validation.

2. Protocole expérimentale commun

2.2. Entrainement

Chaque réseau est entraîné au maximum 200 époques. Nous utilisons l'arrêt anticipé (early stopping) : à chaque époque, on calcule l'erreur sur la validation. Si elle ne s'améliore plus pendant 20 époques, l'entraînement s'arrête et on garde les poids de la meilleure époque. Cela évite de continuer à entraîner un réseau qui commence à surapprendre.

2.3. Règle de comparaison

Les expériences suivent une démarche séquentielle : un seul paramètre est modifié à la fois, en conservant la meilleure configuration précédente, afin d'identifier son influence sur les performances.

Chaque configuration est entraînée cinq fois avec des graines aléatoires différentes (0 à 4). Les résultats sont présentés sous forme de moyenne et d'écart-type, ce dernier permettant d'apprécier la stabilité du modèle.

Pour comparer les configurations, les intervalles [moyenne − écart-type ; moyenne + écart-type] sont examinés. Leur chevauchement ne permet pas de conclure à une différence nette ; cette règle constitue un repère descriptif et non un test statistique.

Enfin, la reproductibilité des expériences a été vérifiée : les mêmes configurations, exécutées avec les mêmes graines aléatoires, produisent les mêmes résultats. Cela confirme la cohérence du protocole expérimental.

2.4. Métriques

Comme 60 % des observations appartiennent à Rubber, l'accuracy (part de bonnes prédictions) est trompeuse. Notre critère principal est donc le Macro-F1. Pour chaque classe, le F1 combine la précision (quand le modèle annonce cette classe, a-t-il raison ?) et le rappel (retrouve-t-il les observations de cette classe ?). Le Macro-F1 est la moyenne des F1 des 8 classes, chacune avec le même poids. Une classe rare compte donc autant que Rubber.

Métrique	Ce qu'elle mesure
Macro-F1 (critère principal)	Qualité moyenne sur les 8 classes, chacune avec le même poids
Précision et rappel macro	Fausses alertes et observations manquées, en moyenne par classe
MCC	Qualité globale, robuste au déséquilibre des classes
Accuracy	Part de bonnes prédictions (à comparer à 60 %)
Écart F1 entraînement − validation	Surapprentissage : plus il est grand, plus le modèle surapprend
Meilleure époque, temps	Vitesse de convergence et coût de calcul

Le Kappa de Cohen, proposé dans l'énoncé, n'a pas été retenu. Son usage pour évaluer et comparer des cartes issues de classification est aujourd'hui contesté, car la correction par l'accord « dû au hasard » n'a pas de sens clair dans ce contexte (Foody, 2020). Le MCC remplit le rôle d'indicateur global robuste au déséquilibre.

II. LES EXPERIENCES

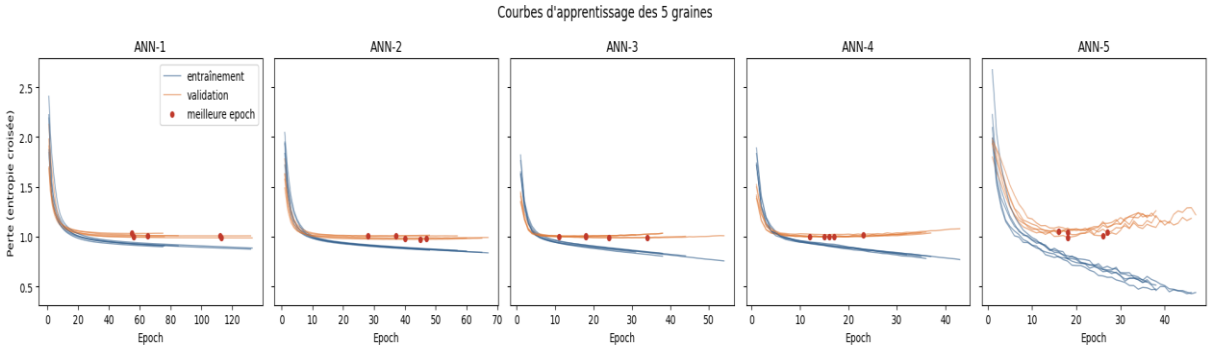
1. Expérience A : faut-il un réseau plus profond ?

Un réseau plus grand classe-t-il mieux ? Nous comparons cinq architectures. Elles vont d'une seule couche de 32 neurones (ANN-1) à quatre couches (ANN-4). L'ANN-5 reprend l'ANN-3 en ajoutant deux techniques de régularisation : la Batch Normalization, qui normalise les valeurs à l'intérieur du réseau, et le Dropout, qui éteint au hasard 20 % des neurones à chaque étape d'entraînement. Toutes utilisent l'optimiseur Adam.

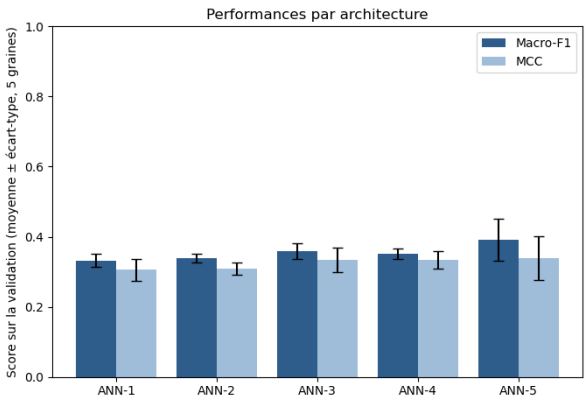
Modèle	Couches cachées	Paramètres	Macro-F1	MCC	Écart train − val	Meilleure époque
ANN-1	32	904	0,332 ± 0,019	0,306 ± 0,031	0,101 ± 0,041	80 ± 30
ANN-2	64-32	3 624	0,338 ± 0,012	0,309 ± 0,017	0,116 ± 0,017	39 ± 8
ANN-3	128-64-32	13 160	0,358 ± 0,022	0,327 ± 0,033	0,102 ± 0,005	21 ± 9
ANN-4	128-128-64-32	29 672	0,352 ± 0,015	0,333 ± 0,026	0,094 ± 0,023	17 ± 4
ANN-5	ANN-3 + BN + Dropout	13 608	0,391 ± 0,060	0,335 ± 0,060	0,080 ± 0,029	21 ± 5

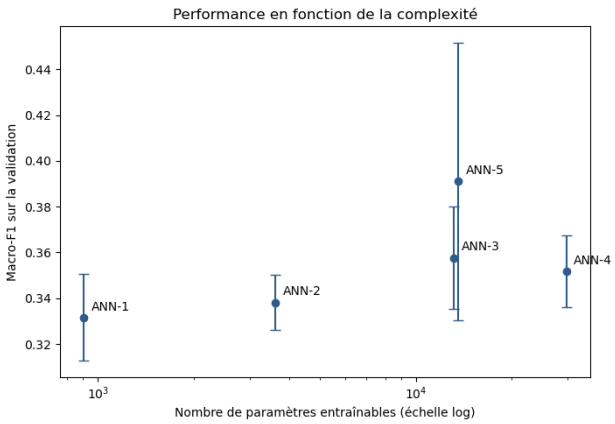
L'accuracy ne départage pas les modèles : elle reste entre 0,64 et 0,66, proche de la part de la classe majoritaire. La lecture s'appuie donc sur le Macro-F1, le rappel macro et le MCC.

- **Architecture intermédiaire (ANN-1 → ANN-2) :** Ajouter une couche ne change presque rien : le Macro-F1 passe de 0,332 à 0,338, un gain inférieur aux écart type. ANN-2 converge en revanche deux fois plus vite (meilleure epoch 39 contre 80).
- **Profondeur et largeur (ANN-1 → ANN-3)** : ANN-3 obtient le meilleur Macro-F1 des réseaux sans régularisation (0,358). Le rappel macro (0,337 → 0,367) et le MCC (0,306 → 0,335) progressent aussi. Les intervalles se chevauchent encore : c'est une tendance, pas un écart net.
- **Couche supplémentaire (ANN-3 → ANN-4) :** Avec plus du double de paramètres, ANN-4 n'apporte aucun gain (Macro-F1 de 0,352). La performance plafonne dès ANN-3.
- **Régularisation (ANN-3 → ANN-5) :** ANN-5 a la meilleure moyenne (0,391), mais avec écart type presque trois fois plus grand (± 0,061) : son résultat dépend fortement de la graine. Le seul écart type net de l'expérience porte sur la précision macro (0,519 contre 0,393). Le rappel macro, lui, est identique (0,369 contre 0,367). ANN-5 annonce donc ses classes à plus juste titre, sans en retrouver davantage.



Les courbes d'apprentissage montrent que plus le réseau est profond, plus il apprend vite et plus le surapprentissage apparaît tôt. Pour ANN-1 et ANN-2, les deux pertes baissent ensemble puis se stabilisent autour de 1,0. Pour ANN-3 et surtout ANN-4, la perte de validation remonte légèrement en fin d'entraînement. ANN-5 est le cas le plus marqué : la perte d'entraînement descend jusqu'à environ 0,45, tandis que celle de validation remonte dès une vingtaine d'epochs, avec des courbes irrégulières.





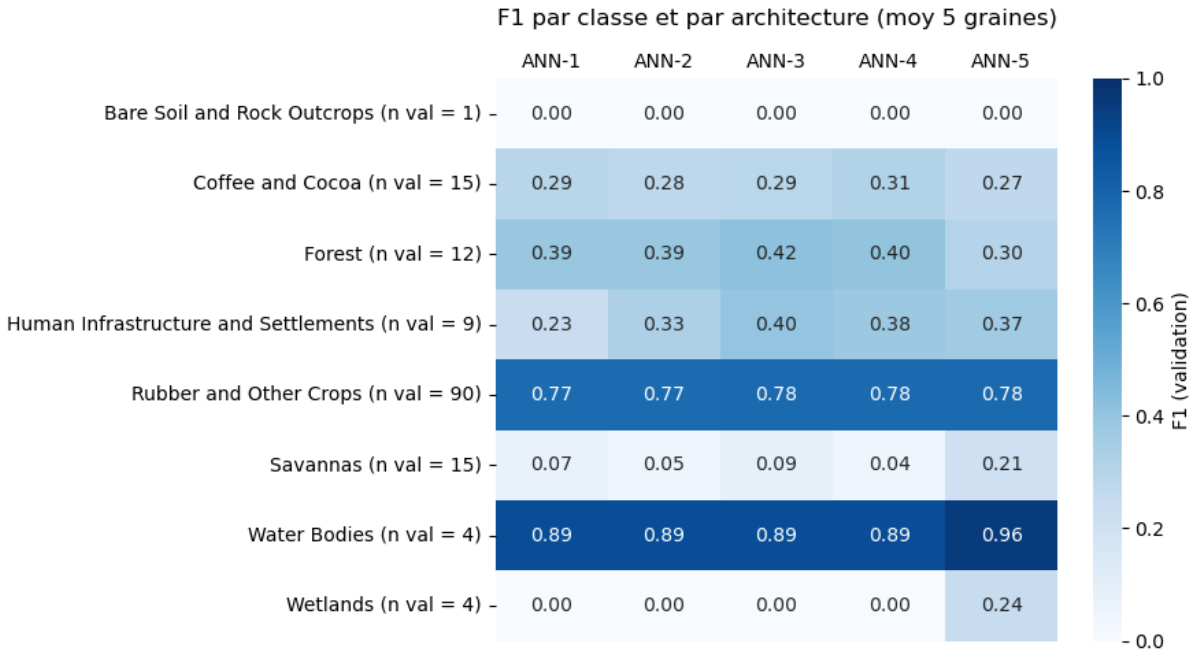
Performance en fonction de la complexité

Le Macro-F1 tend à augmenter avec la complexité entre l'ANN-1 et l'ANN-3, puis plafonne : l'ANN-4, avec plus du double de paramètres, n'apporte pas de gain (0,352). Les barres d'erreur se chevauchent pour toutes les architectures. L'ANN-5 a presque le même nombre de paramètres que l'ANN-3 ; sa baisse de Macro-F1 (0,332) n'est donc pas liée à la complexité, mais à la régularisation ajoutée, avec laquelle le modèle surapprend plus vite.

Performances par architecture

Le Macro-F1 et le MCC évoluent dans le même sens : l'ANN-3 et l'ANN-4 obtiennent les valeurs les plus élevées, l'ANN-5 les plus faibles. Les écarts entre architectures restent du même ordre que les écarts-types. Les scores restent modestes (Macro-F1 inférieur à 0,36 pour toutes les architectures) : l'architecture n'est pas le principal facteur limitant.

Performance par classe

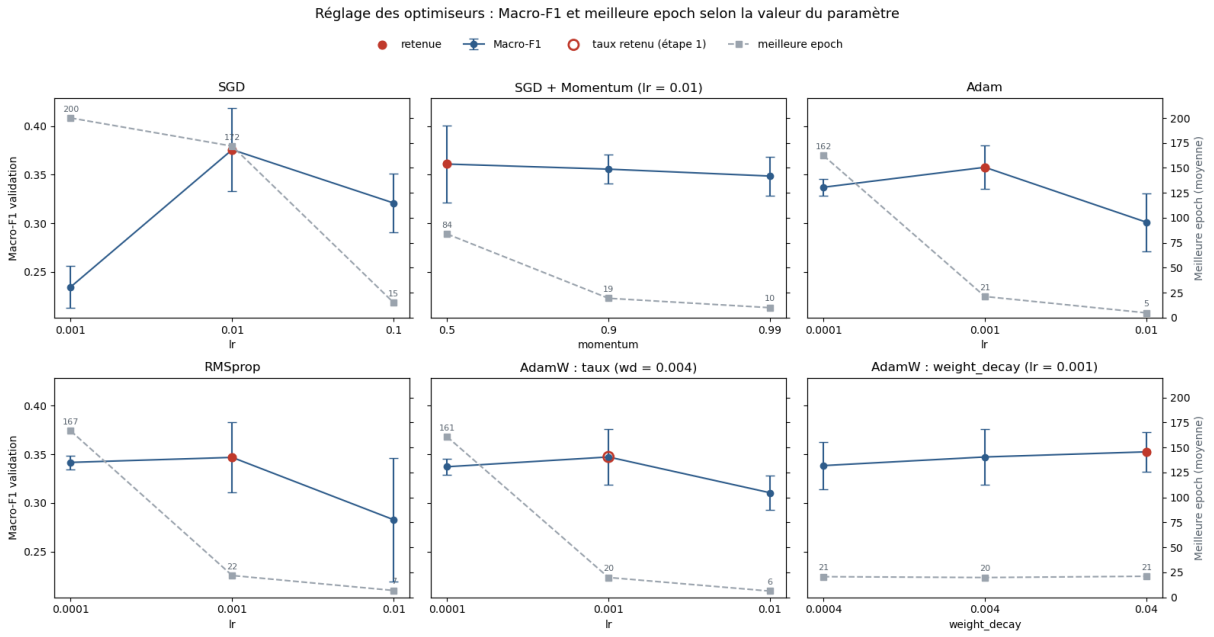


Les architectures présentent des résultats similaires : Water Bodies et Rubber sont bien reconnues, contrairement à Bare Soil et Savannas. L'augmentation de la taille du réseau améliore surtout Human Infrastructure. L'ANN-5 se démarque sur Savannas (F1 = 0,21) et Wetlands (0,24), mais ces scores reposent sur peu d'observations en validation.

Choix retenu : l'ANN-3. C'est le plus petit réseau qui atteint le plateau des modèles sans régularisation, avec un résultat très stable d'une graine à l'autre. Nous ne retenons pas l'ANN-5, car sa moyenne repose sur deux graines et quelques observations.

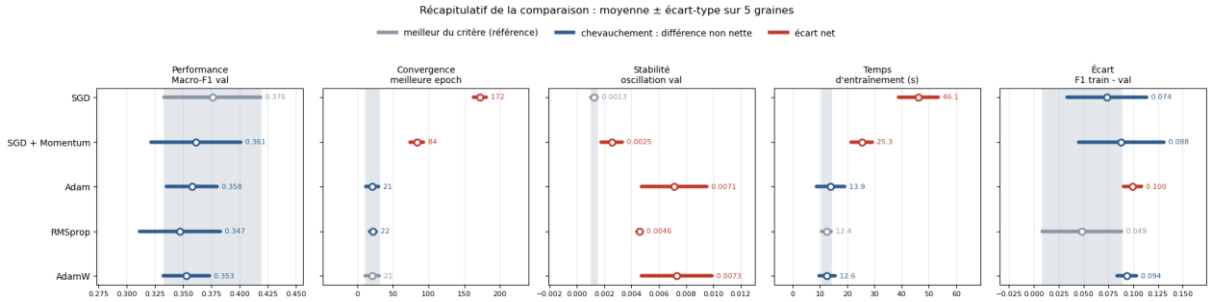
2. Expérience B : quel optimiseur choisir ?

Avec l'ANN-3, cinq optimiseurs sont comparés : SGD, Momentum, Adam, RMSprop et AdamW. Les trois derniers adaptent automatiquement le taux d'apprentissage, tandis que Momentum ajoute une inertie au SGD et qu'AdamW pénalise les poids trop élevés. Pour une comparaison équitable, trois taux d'apprentissage sont testés pour chaque optimiseur, avec cinq graines. Le momentum (SGD) et le weight decay (AdamW) sont ensuite ajustés.

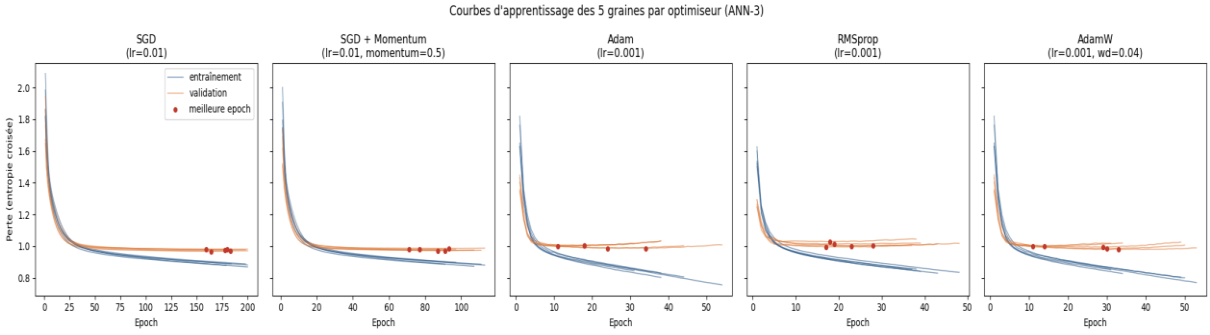


Le taux d'apprentissage est le réglage qui compte le plus. Pour SGD, le Macro-F1 passe de 0,235 avec un taux de 0,001 (pas trop petits : le réseau n'a pas fini d'apprendre en 200 époques) à 0,376 avec 0,01. Pour les optimiseurs adaptatifs, un taux de 0,01 est trop grand et donne les moins bons scores ; 0,001 est le meilleur choix. Le Momentum et le weight decay changent peu le Macro-F1, mais le Momentum.

Comparaison des optimiseurs

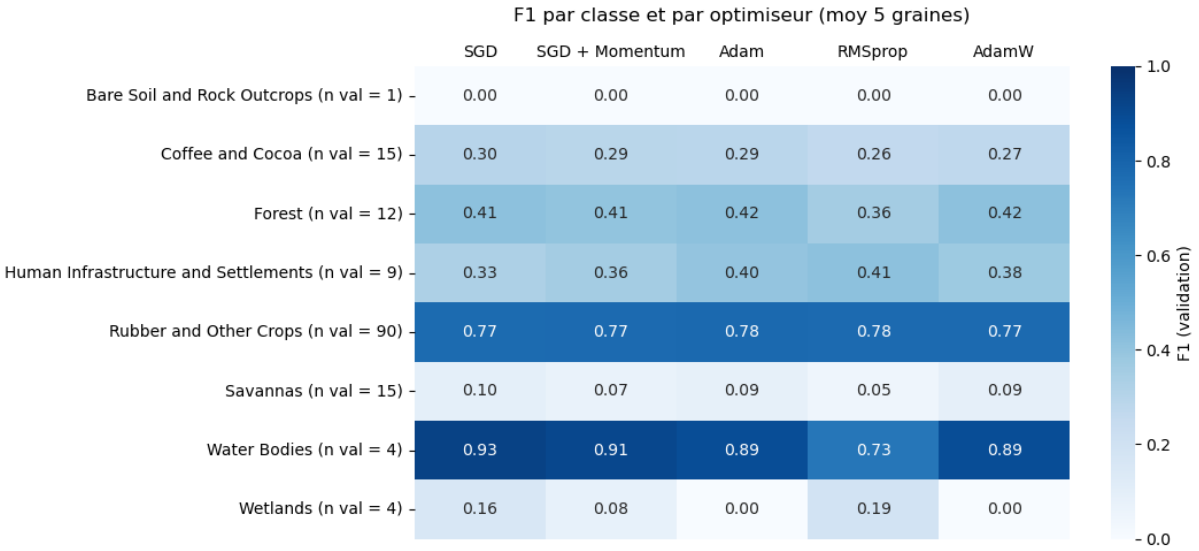


- Performance : Les intervalles de Macro-F1 se chevauchent tous. SGD a la meilleure moyenne (0,376), mais aussi le plus grand écart-type (± 0,043).
- Convergence et temps : SGD est nettement le plus lent : sa meilleure epoch (172) est proche du budget. Le momentum divise par deux la convergence (84 epochs) et le temps (25,3 s). Les optimiseurs adaptatifs convergent en une vingtaine d'epochs, en 12 à 14 s.
- Stabilité : SGD a les courbes les plus stables, suivi de SGD + Momentum. Adam et AdamW oscillent nettement plus (instabilité environ trois fois plus grande).
- Écart entraînement / validation : RMSprop a le plus petit écart (0,049), mais très variable d'une graine à l'autre. Adam a le seul écart net (0,100). Le weight decay d'AdamW ne réduit pas cet écart par rapport à Adam.



Avec SGD et SGD + Momentum, les courbes sont les plus régulières : les pertes d'entraînement et de validation diminuent ensemble et restent proches, et la perte de validation ne remonte pas. SGD + Momentum converge environ deux fois plus vite que SGD (meilleure epoch d'environ 86 contre 173). Avec Adam, RMSprop et AdamW, la convergence est beaucoup plus rapide (une vingtaine d'epochs), mais la perte d'entraînement continue de baisser alors que la perte de validation se stabilise puis remonte légèrement : un début de surapprentissage apparaît, interrompu par l'arrêt anticipé. Comme dans l'expérience A, l'initialisation influence le moment optimal d'arrêt, surtout pour les optimiseurs adaptatifs (meilleure epoch d'environ 11 à 34 selon la graine pour Adam), alors qu'elle varie peu pour SGD.

Performance par classe



Le profil des classes ne change pas avec l'optimiseur : Bare Soil n'est jamais reconnue, Savannas presque jamais (F1 de 0,05 à 0,09), Water Bodies et Rubber restent les mieux reconnues. Les seules différences touchent Wetlands et Water Bodies, avec 4 observations de validation chacune, trop peu pour être attribuées à l'optimiseur. Les difficultés viennent donc des données, pas de l'algorithme d'optimisation.

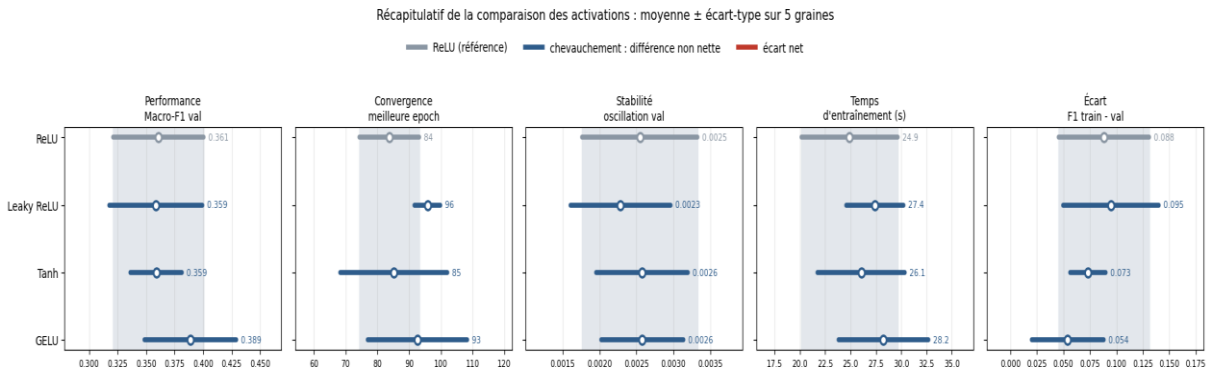
Choix retenu : **SGD + Momentum** (taux 0,01, momentum 0,5). À performance égale, il offre des courbes régulières, sans remontée de l'erreur de validation, et converge dans le budget d'époques. L'énoncé le rappelle d'ailleurs : un optimiseur ne doit pas être choisi seulement parce qu'il converge vite ; la qualité de la généralisation passe en premier.

3. Expérience C : quelle fonction d'activation ?

La fonction d'activation est la transformation non linéaire appliquée par chaque neurone. Nous comparons quatre fonctions dans les couches cachées : ReLU , Leaky ReLU, Tanh, GELU. La couche de sortie reste en softmax. Les quatre modèles ont exactement 13 160 paramètres : l'activation ne modifie pas le nombre de poids.

Activation	Macro-F1	Précision macro	Rappel macro	MCC	Écart F1 train − val	Meilleure epoch	Temps (s)
ReLU	**0,361 ± 0,040**	**0,444 ± 0,104**	**0,361 ± 0,030**	**0,326 ± 0,036**	**0,088 ± 0,043**	**84 ± 9**	**24,9 ± 4,8**
Leaky ReLU	**0,359 ± 0,041**	**0,438 ± 0,091**	**0,359 ± 0,032**	**0,321 ± 0,036**	**0,095 ± 0,045**	**96 ± 4**	**27,4 ± 2,9**
Tanh	**0,359 ± 0,023**	**0,445 ± 0,061**	**0,364 ± 0,020**	**0,338 ± 0,037**	**0,073 ± 0,017**	**85 ± 17**	**26,1 ± 4,3**
GELU	**0,389 ± 0,041**	**0,469 ± 0,097**	**0,377 ± 0,023**	**0,330 ± 0,025**	**0,054 ± 0,034**	**93 ± 16**	**28,2 ± 4,5**

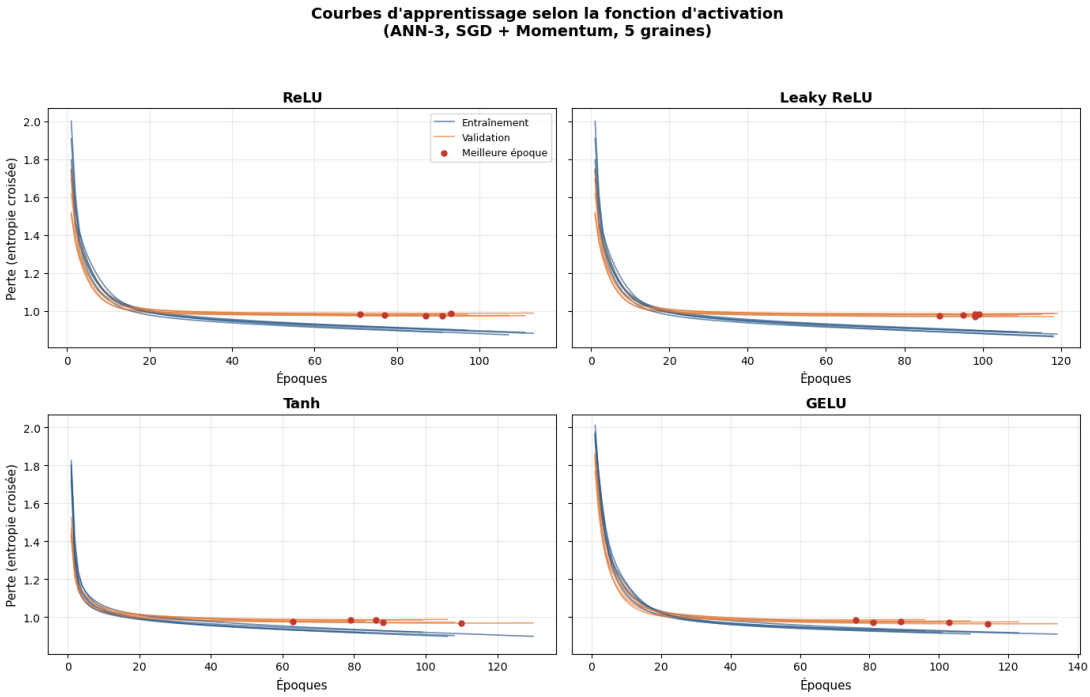
Avec ReLU, les Macro-F1 obtenus sont identiques, graine par graine, à ceux de SGD + Momentum dans l'expérience B, où ReLU était l'activation par défaut. Ce résultat confirme la reproductibilité du protocole.



Sur les cinq critères, toutes les barres sont bleues : aucune activation ne se distingue nettement de ReLU.

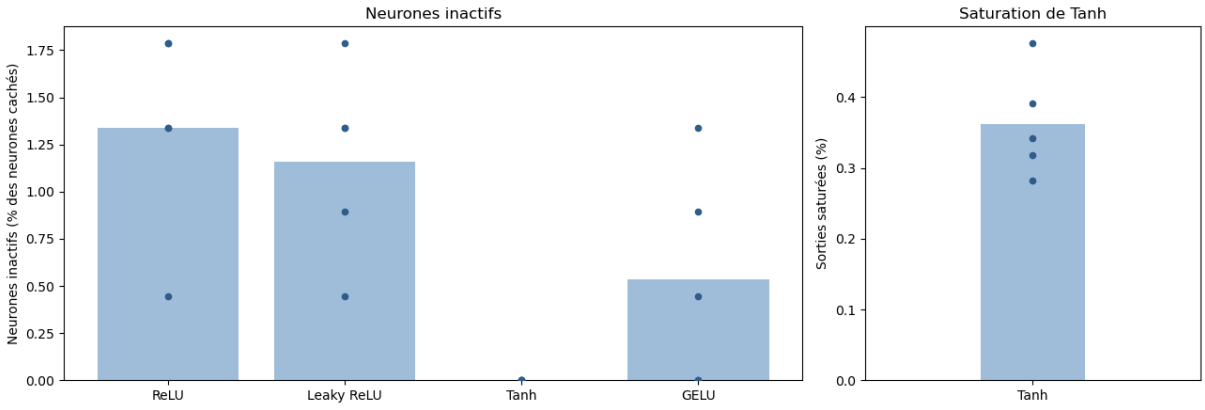
- **Performance :** GELU est devant en moyenne (0,389), mais sa barre chevauche largement celle de ReLU.
- **Convergence :** toutes trouvent leur meilleure epoch entre 85 et 96 en moyenne. Leaky ReLU est un peu plus tardive (96), sans écart net.
- **Stabilité** : les courbes oscillent très peu pour toutes les activations (entre 0,002 et 0,003).
- **Temps :** ReLU est la plus rapide (71,8 s), mais les autres restent proches.
- **Écart entraînement / validation :** GELU a le plus petit (0,054) et Leaky ReLU le plus grand (0,098), sans écart net là non plus.

En résumé, Le changement de fonction d'activation n'améliore pas nettement la qualité de la classification.



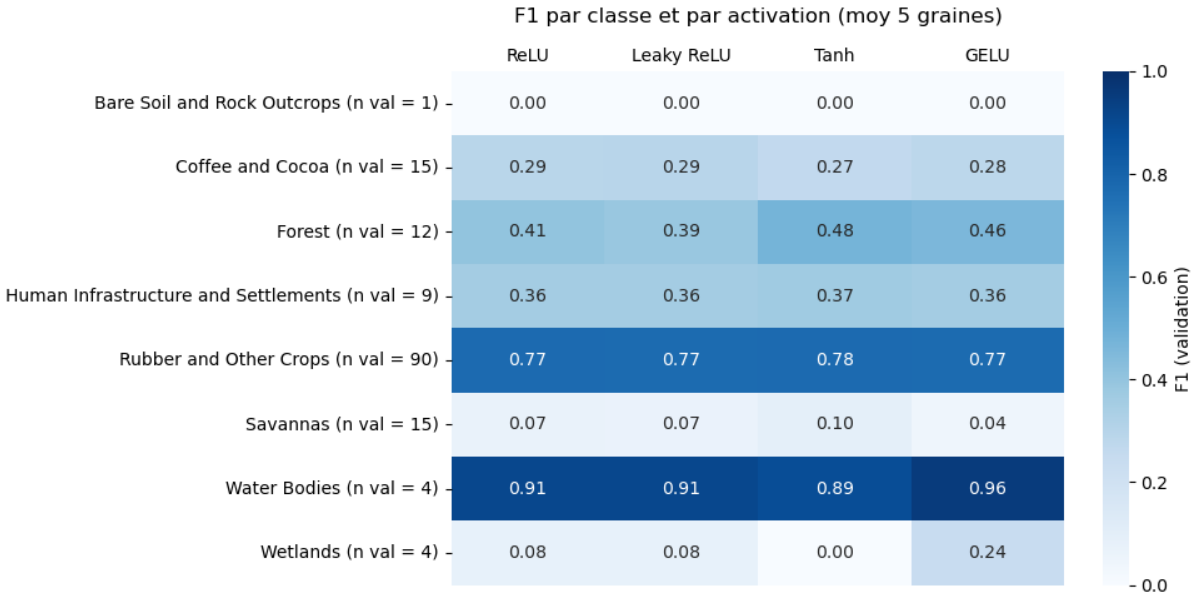
Les courbes des quatre activations se ressemblent beaucoup. Pendant les vingt premières epochs environ, les pertes d'entraînement et de validation baissent rapidement et ensemble. Ensuite, la perte de validation se stabilise autour de 0,97 et ne remonte pas, tandis que la perte d'entraînement continue de baisser doucement. Le modèle commence donc à mieux connaître les données d'entraînement que les nouvelles données, mais sans vrai surapprentissage. Tanh fait baisser la perte un peu plus vite au tout début, puis rejoint les autres.

Comme la perte de validation forme un plateau très plat, le moment exact où elle est la plus basse varie selon la graine (de 63 à 110 epochs pour Tanh). Cela explique les écarts-types assez grands sur la convergence.



Les deux défauts connus de ces activations sont presque absents ici :

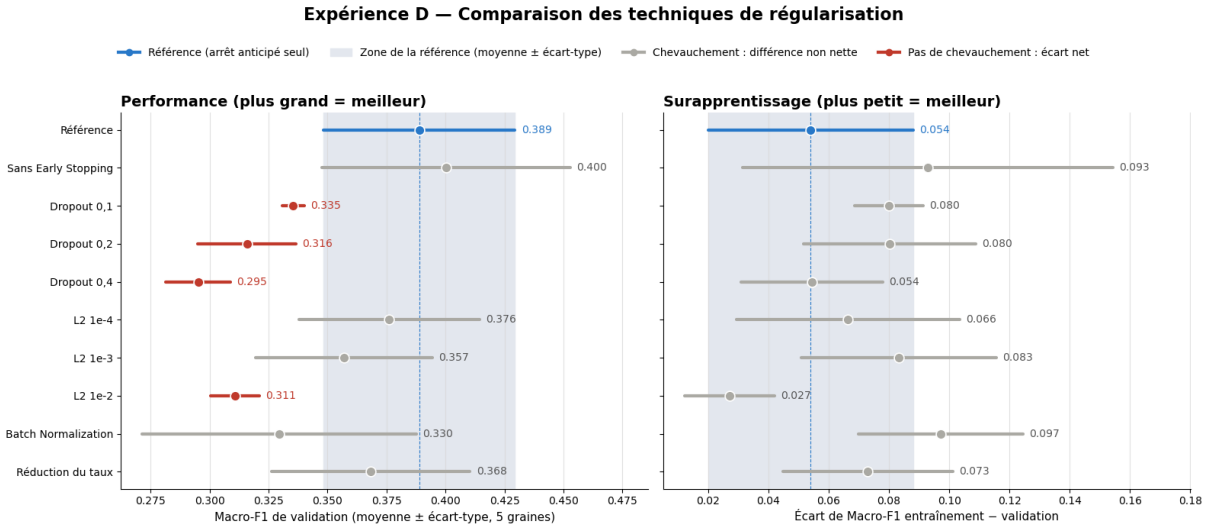
- **Neurones « morts ».** Avec ReLU, 1,3 % des 224 neurones cachés sont inactifs en moyenne, soit environ 3 neurones (4 au maximum). Leaky ReLU, conçue pour éviter ce problème, n'a donc presque rien à corriger.
- **Saturation.** Seulement 0,4 % des sorties de Tanh sont collées à −1 ou 1. La standardisation des entrées garde les valeurs dans une plage où Tanh ne sature pas.



Le profil des classes reste le même. Tanh et GELU reconnaissent un peu mieux Forest (0,48 et 0,46 contre 0,41 pour ReLU). La seule différence marquée concerne Wetlands, mieux reconnue avec GELU (0,24 contre 0,08). Cette classe n'a que 4 observations en validation : elle explique à elle seule environ 0,02 point de l'avance de GELU, soit les deux tiers de son écart avec ReLU (0,028).

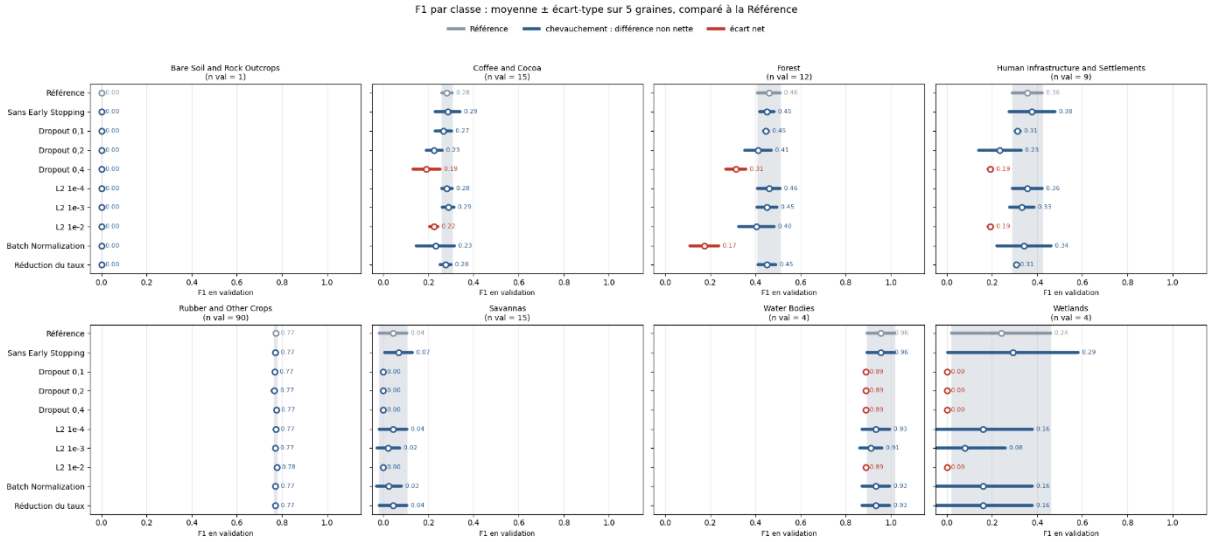
Choix retenu : GELU. Sans écart net avec ReLU, elle obtient le Macro-F1 moyen le plus élevé, fait mieux que ReLU pour 4 graines sur 5 et présente le plus faible écart entre entraînement et validation, pour une stabilité et un coût comparable. Son avantage reste fragile, car il repose en partie sur une classe de 4 observations.

4. Expérience D : la régularisation réduit-elle le surapprentissage ?



Aucune configuration ne combine un écart plus faible et un Macro-F1 au moins égal à celui de la référence. Le Dropout réduit les performances, même s'il stabilise les résultats à 0,1. La L2 forte (10^{-2}) réduit l'écart, mais provoque un sous-apprentissage. La Batch Normalization accélère la convergence, mais entraîne une forte instabilité et un surapprentissage précoce. Sans arrêt anticipé, l'entraînement est plus long et moins stable. Enfin, la réduction du taux d'apprentissage n'apporte pas d'amélioration notable.

Les courbes confirment ces observations. Avec la L2 forte, les pertes d'entraînement et de validation restent proches, mais continuent de diminuer à 200 epochs, signe de sous-apprentissage. Avec la Batch Normalization, la perte de validation remonte après une vingtaine d'epochs, indiquant un surapprentissage précoce. Enfin, le Dropout freine l'apprentissage de ce petit réseau : la perte d'entraînement reste supérieure à celle de validation, car certains neurones sont désactivés pendant l'entraînement.



Aucune régularisation n'améliore nettement la reconnaissance des classes. Les plus fortes (Dropout 0,4, L2 10^{-2} et Batch Normalization) dégradent surtout Coffee and Cocoa, Forest et Human Infrastructure. Le Dropout fait également chuter les scores de Water Bodies et de Wetlands (F1 nul).

Choix retenu : la référence (arrêt anticipé seul). Celui-ci limite déjà le surapprentissage, tandis que les régularisations fortes réduisent les performances. Son retrait confirme son utilité : l'écart augmente et l'entraînement dure plus longtemps, sans gain notable. Par ailleurs, le gain moyen d'ANN-5 pourrait s'expliquer par la combinaison du Dropout et de la Batch Normalization, le contexte différent (ReLU et Adam) ou la variabilité entre graines. Les limites restantes relèvent surtout du déséquilibre des classes et du chevauchement spectral, plutôt que du surapprentissage.

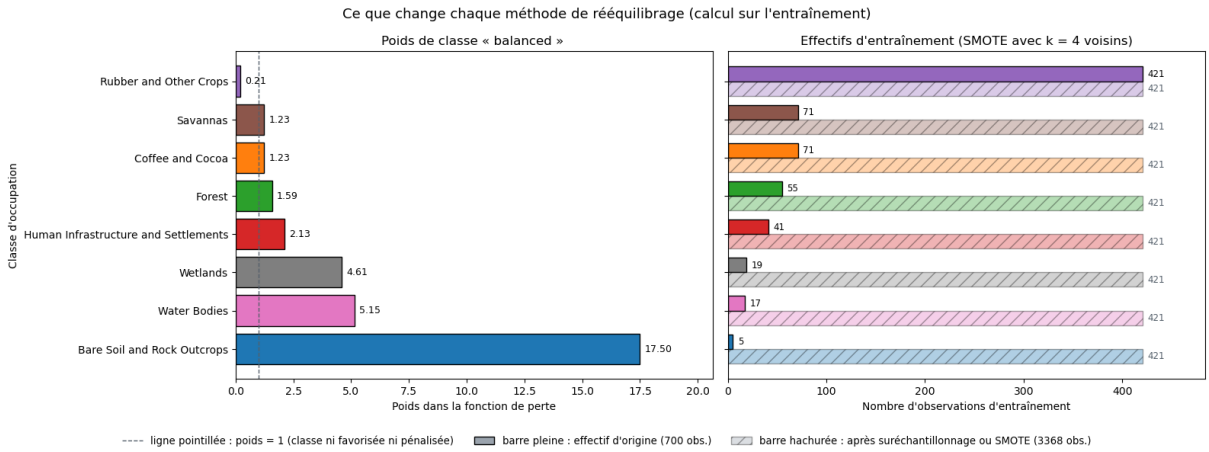
5. Expérience E : Gestion du déséquilibre de classe

Dans l'ensemble d'entraînement, la classe la plus fréquente (Rubber, 421 observations) est 84 fois plus représentée que la plus rare (Bare Soil, 5 observations). Quatre méthodes ont été comparées avec le modèle retenu (ANN-3, SGD + Momentum, GELU, arrêt anticipé) :

Méthode	Principe	Effectif d'entraînement
Sans correction	Référence	700
Poids de classe	Erreurs sur les classes rares plus pénalisées dans la perte ; poids de 0,21 pour Rubber à 17,5 pour Bare Soil	700
Suréchantillonnage	Copies aléatoires des observations rares jusqu'à 421 par classe	3 368
SMOTE	Observations synthétiques créées entre voisins d'une même classe (Chawla et al., 2002)	3 368

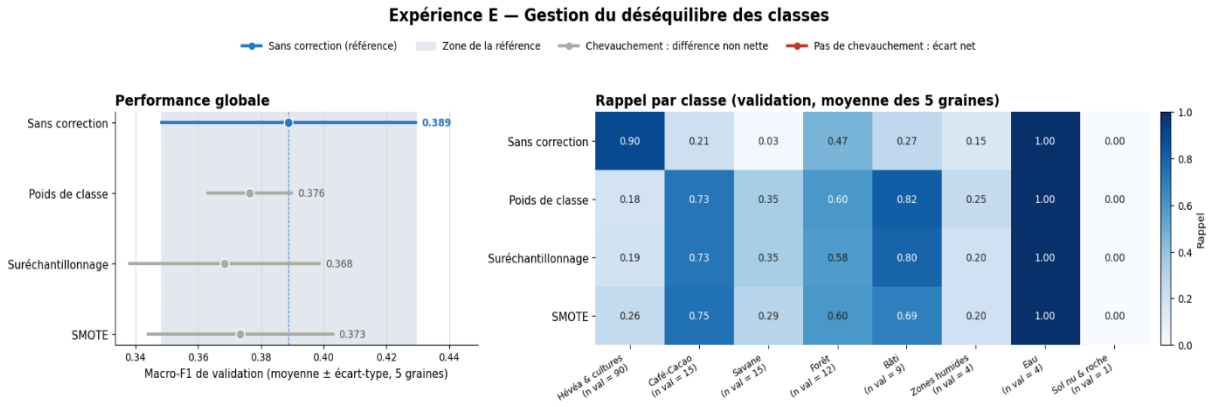
Le suréchantillonnage et SMOTE sont appliqués uniquement à l'entraînement.

Les trois méthodes agissent différemment, mais dans le même sens. Les poids de classe ne changent pas les données : ils multiplient l'erreur commise sur chaque classe, de 0,21 pour Rubber à 17,5 pour Bare Soil. Le suréchantillonnage et SMOTE changent les données : chaque classe est portée à 421 observations. Dans les deux cas, chaque classe pèse autant que les autres dans la fonction de perte.



Poids de classe « balanced » et effectifs d'entraînement avant et après suréchantillonnage ou SMOTE

Méthode	Macro-F1	Rappel macro	Précision macro	Accuracy	Écart F1 train − val
Sans correction	**0,389 ± 0,041**	0,377 ± 0,023	0,469 ± 0,097	0,645 ± 0,011	0,054 ± 0,034
Poids de classe	0,376 ± 0,013	0,492 ± 0,023	0,384 ± 0,023	0,347 ± 0,053	0,033 ± 0,041
Suréchantillonnage	0,368 ± 0,030	0,482 ± 0,021	0,377 ± 0,035	0,348 ± 0,025	0,051 ± 0,036
SMOTE	0,373 ± 0,030	0,473 ± 0,028	0,374 ± 0,037	0,379 ± 0,017	0,046 ± 0,049



Les trois méthodes produisent le même effet : le rappel macro augmente (0,377 à 0,47–0,49), mais la précision macro et l'accuracy diminuent. Le Macro-F1 reste comparable à la référence (0,389), sans réduction nette de l'écart entre entraînement et validation.

Sans rééquilibrage, le modèle favorise Rubber (60 % des données) au détriment des classes minoritaires. Le rééquilibrage améliore le rappel de Coffee and Cocoa, Human Infrastructure, Forest et Savannas, mais fait chuter celui de Rubber (0,18–0,26). Cela explique la baisse de l'accuracy. Water Bodies reste bien reconnue, tandis que Bare Soil n'est toujours pas détectée, faute d'observations suffisantes à l'entraînement.

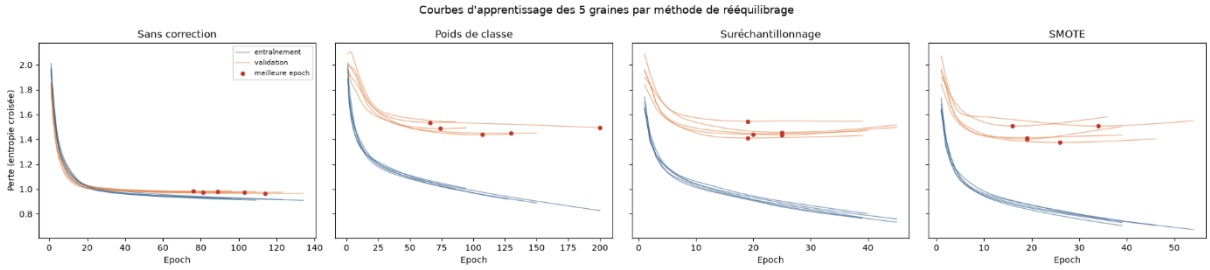


Figure : Courbes d'apprentissage des 5 graines par méthode de rééquilibrage

Les courbes montrent une perte de validation plus élevée après rééquilibrage (1,4–1,5 contre 0,97). Cela ne traduit pas nécessairement un surapprentissage : le modèle est entraîné sur des données rééquilibrées, mais évalué sur des données déséquilibrées, où ses erreurs sur Rubber augmentent la perte. Le suréchantillonnage et SMOTE convergent plus tôt en raison du nombre plus élevé de mises à jour par époque.

Choix retenu : sans correction. Le rééquilibrage améliore certaines classes, mais déplace les erreurs de Rubber vers les classes minoritaires sans améliorer nettement le Macro-F1. SMOTE ne fait pas mieux que le suréchantillonnage simple. La configuration de référence est donc conservée.

6. Expérience F : Quelles familles de variables contribuent le plus à la classification ?

Nous comparons trois jeux de variables : les 10 bandes (F1), les 9 indices (F2) et les 19 variables ensemble (F3, la configuration utilisée jusqu'ici). Seule l'entrée du réseau change ; chaque jeu a sa propre standardisation.

Avant l'entraînement, nous avons vérifié la redondance des indices sur l'ensemble d'entraînement. Neuf paires d'indices ont une corrélation de rang supérieure à 0,98 en valeur absolue. Le NDMI et le MSI sont liés par une relation exacte. Les 9 indices résument donc surtout trois informations : la végétation, l'humidité et la brillance.

Configuration	Variables	Nombre	Question étudiée
F1	B1 à B10	10	Les bandes spectrales suffisent-elles ?
F2	NDVI, EVI, NDRE, SAVI, NDMI, NDWI, MSI, BSI, BI	9	Les indices sont-ils plus discriminants ?
F3 (référence)	Bandes + indices	19	La fusion améliore-t-elle les résultats ?

Relations entre les indices. Comme le demande l'énoncé, la redondance des indices a d'abord été vérifiée sur l'entraînement (corrélation de Spearman). Neuf paires ont $|\rho| \geq 0{,}98$, par exemple EVI et SAVI (0,999) ou NDVI et EVI (0,994). NDMI et MSI sont même liés par une relation exacte : $NDMI = (1 - MSI) / (1 + MSI)$

Les 9 indices résument donc trois informations : la végétation (NDVI, EVI, SAVI, NDWI en sens inverse, NDRE dans une moindre mesure), l'humidité et l'infrarouge moyen (NDMI, MSI, BSI) et la brillance (BI).

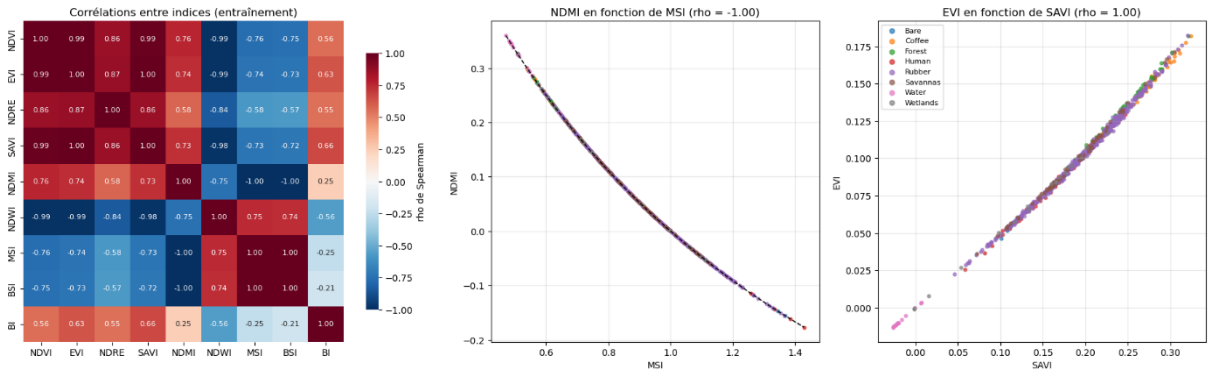


Figure : Corrélations de Spearman entre les indices (entraînement).

- **Bandes seules (F1) :** 0,365, proche de F3 : les bandes suffisent en grande partie.
- **Indices seuls (F2) :** les plus basses moyennes et une convergence nettement plus lente (meilleure epoch 133 contre 93), seul écart net de l'expérience. Calculés à partir des bandes, les indices n'apportent pas d'information nouvelle.
- **Fusion (F3) :** meilleures moyennes sur tous les critères, mais sans écart net.

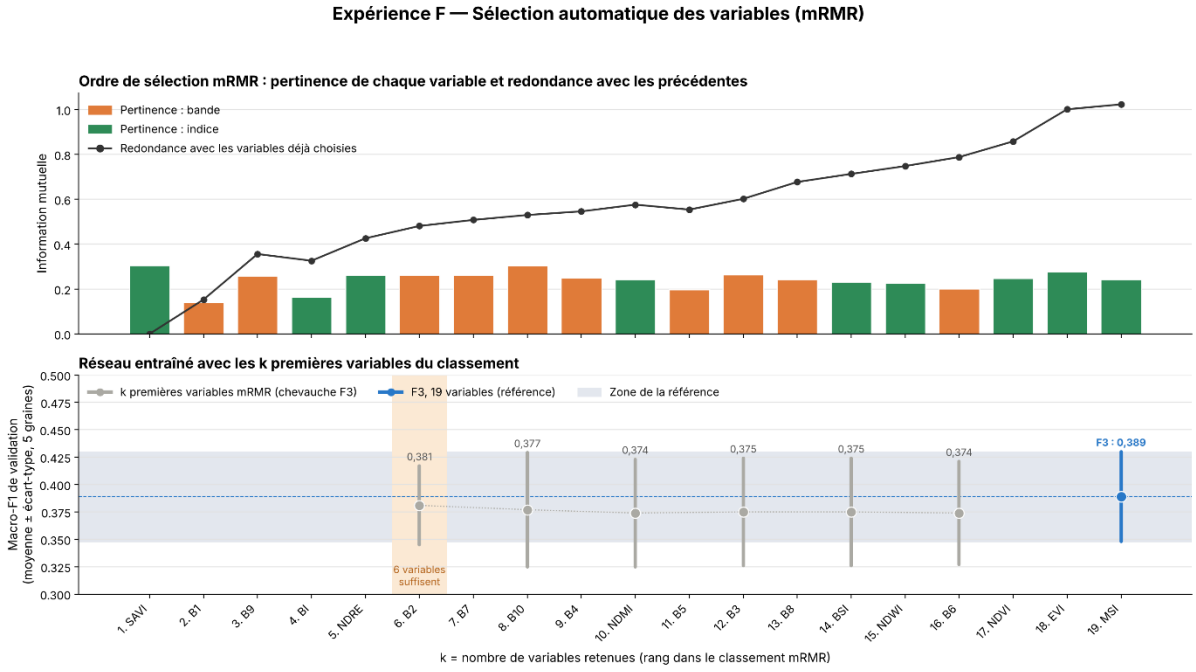
Quelles que soient les variables, les erreurs vont surtout vers Rubber : Bare Soil et Savannas ne sont presque jamais reconnues. Les deux familles restent complémentaires : les bandes retrouvent mieux le bâti (0,31 contre 0,18 avec les indices), et la fusion améliore la forêt (0,47).

Choix retenu : F3 (bandes + indices), pour ses meilleures moyennes et sa convergence plus rapide, pour seulement 1 152 paramètres de plus que F1.

- **Sélection automatique des variables et validation spatiale**

Sélection des variables par mRMR :

La méthode mRMR (Peng et al., 2005) classe les variables en retenant à chaque étape celle qui apporte le plus d'information sur la classe tout en répétant le moins les variables déjà choisies (information mutuelle, calculée sur l'entraînement). Le réseau a ensuite été entraîné avec les k premières variables (k = 6 à 16, 5 graines chacune).

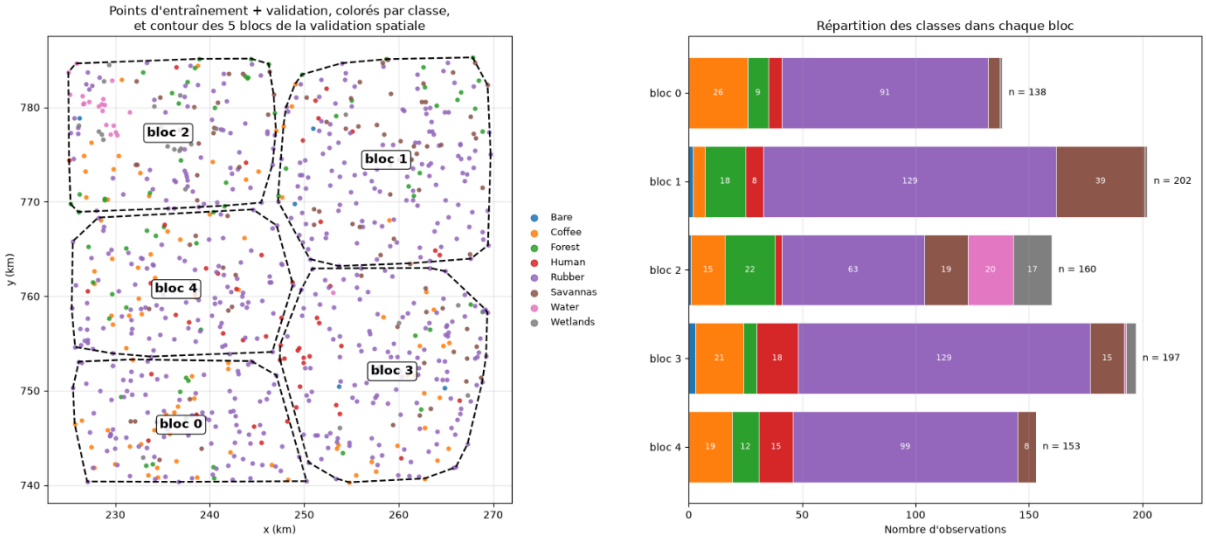


SAVI arrive en premier, suivie de B1, B9, BI, NDRE et B2, peu redondantes entre elles. EVI et MSI arrivent en dernier, car elles répètent SAVI et NDMI. Avec ces 6 premières variables, le réseau atteint déjà un Macro-F1 de 0,381, proche de F3 ; en ajouter n'améliore plus rien.

Configuration	Variables	Macro-F1	Rappel macro	Précision macro	Accuracy	Écart F1 train − val
mRMR k = 6	6	0,381 ± 0,036	0,369 ± 0,023	0,525 ± 0,076	0,653 ± 0,005	0,042 ± 0,027
mRMR k = 8	8	0,377 ± 0,052	0,371 ± 0,032	0,454 ± 0,132	0,643 ± 0,012	0,057 ± 0,047
mRMR k = 10	10	0,374 ± 0,049	0,368 ± 0,027	0,457 ± 0,143	0,647 ± 0,016	0,061 ± 0,047
mRMR k = 12	12	0,375 ± 0,049	0,369 ± 0,027	0,474 ± 0,159	0,648 ± 0,017	0,067 ± 0,043
mRMR k = 14	14	0,375 ± 0,049	0,369 ± 0,027	0,472 ± 0,156	0,648 ± 0,014	0,059 ± 0,053
mRMR k = 16	16	0,374 ± 0,047	0,368 ± 0,027	0,459 ± 0,138	0,644 ± 0,015	0,071 ± 0,064
F3 (référence)	19	**0,389 ± 0,041**	0,377 ± 0,023	0,469 ± 0,097	0,645 ± 0,011	0,054 ± 0,034

Validation spatiale par blocs

Pour mesurer l'effet de la dépendance spatiale (chapitre 1), F3 et mRMR k = 6 ont été comparés par deux validations croisées en 5 plis sur les 850 observations d'entraînement et de validation : des plis tirés au hasard (zones déjà vues), et des plis formés de 5 blocs géographiques obtenus par k-means sur les coordonnées (zone jamais vue). Dans chaque pli, 15 % de l'apprentissage servent à l'arrêt anticipé.



Les blocs ont des tailles comparables (138 à 202 observations), mais le bloc 2 concentre presque toute l'eau et les zones humides : quand il sert de zone inconnue, ces classes n'ont presque plus d'exemples d'apprentissage.

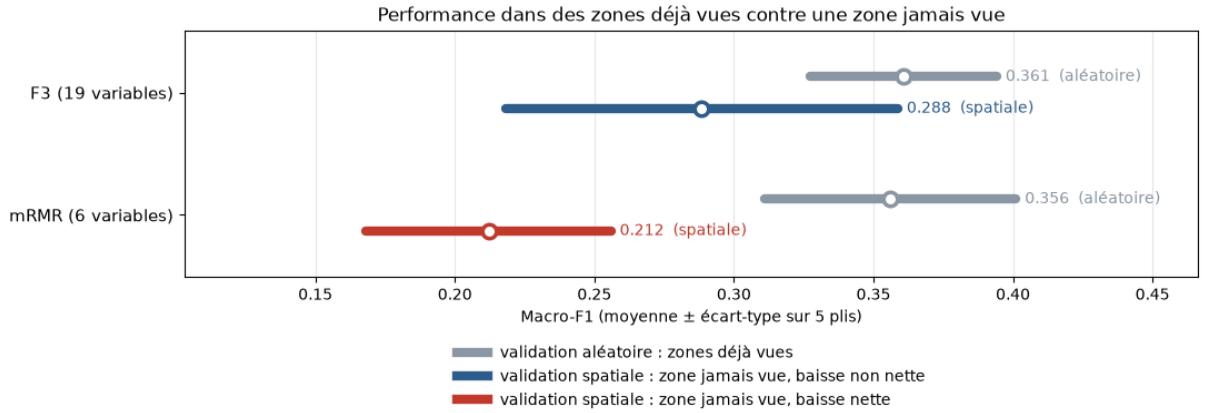


Figure : Macro-F1 en validation aléatoire et en validation spatiale (moyenne ± écart-type sur 5 plis).

Les deux modèles se valent dans les zones vues, mais le modèle à 6 variables perd deux fois plus en zone nouvelle (baisse nette). La validation aléatoire est donc optimiste, et la redondance des 19 variables rend F3 plus robuste. B1 et B2, sensibles aux variations de l'atmosphère à grande distance (chapitre 1), pourraient expliquer la fragilité du modèle réduit.

Choix confirmé : F3 (bandes + indices), aussi performante dans les zones connues et plus robuste dans une zone nouvelle.

CHAPITRE III : COMPARAISON AVEC LES MODELES CLASSIQUES

Les réseaux de neurones sont-ils plus performants que Random Forest, SVM et XGBoost sur ce jeu de données ? Pour le savoir, nous comparons le réseau retenu à des modèles d'apprentissage automatique classiques.

Une comparaison n'est juste que si chaque modèle est traité avec le même soin. Nous avons donc appliqué à chaque modèle le même parcours qu'au réseau : réglage des hyperparamètres, puis choix d'une méthode de rééquilibrage, puis validation croisée aléatoire et spatiale.

I. PROTOCOLE COMMUN

Tous les modèles partent exactement des mêmes éléments que le réseau retenu :

- Les mêmes données : le fichier nettoyé du chapitre 1 et les 19 variables de la configuration F3 (10 bandes et 9 indices), lues dans le fichier config_ann.json ;
- Les mêmes partitions : le découpage 70 / 15 / 15 de l'expérience A. Le notebook vérifie, observation par observation, que les ensembles sont identiques ;
- La même standardisation, apprise sur l'entraînement seulement ;
- Les mêmes 5 graines (0 à 4) pour les modèles qui dépendent du hasard ;
- Les mêmes métriques, avec le Macro-F1 comme critère principal, et la même règle : une différence n'est nette que si les intervalles moyenne ± écart-type ne se chevauchent pas.

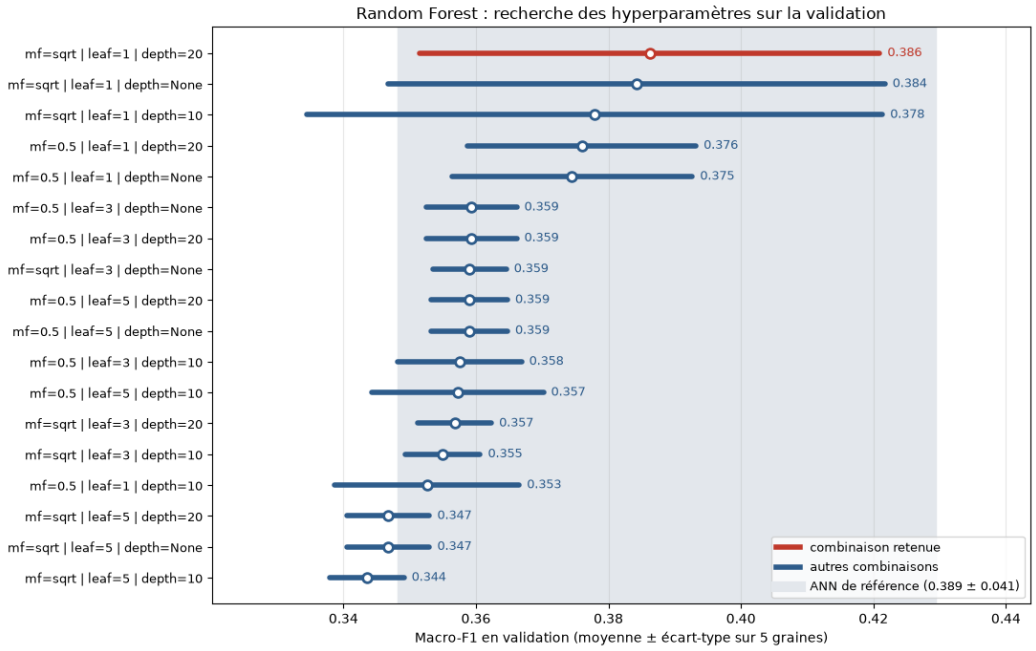
Chaque modèle suit trois étapes : le réglage des hyperparamètres, en retenant la combinaison offrant le meilleur Macro-F1 sur la validation ; le choix de la méthode de rééquilibrage (sans correction, poids de classe, suréchantillonnage ou SMOTE), appliquée uniquement aux données d'entraînement ; puis une validation croisée comprenant cinq plis aléatoires et cinq plis spatiaux, sur les 850 observations d'entraînement et de validation, avec les mêmes blocs géographiques que pour le réseau.

L'ensemble de test reste totalement indépendant et n'est utilisé que pour l'évaluation finale. Les configurations retenues sont enregistrées dans `config_rf.json` et `config_svm.json`.

II. LES MODELES CLASSIQUES

1. Random Forest

La grille compte 18 combinaisons, chacune entraînée avec les 5 graines, soit 90 entraînements.



La meilleure combinaison est max_features = sqrt, min_samples_leaf = 1 et max_depth = 20, avec un Macro-F1 de 0,386 ± 0,035. Elle permet aux arbres d'apprendre des règles détaillées, tandis que le vote de la forêt limite le risque de surapprentissage. À l'inverse, les arbres avec des feuilles plus grandes sont plus stables (écart-type ≈ 0,007), mais obtiennent un Macro-F1 plus faible (0,359), notamment en raison d'une moins bonne prise en compte des classes minoritaires.

Méthode	Macro-F1	Rappel Rubber	Rappel Coffee	Rappel Forest	Rappel Human	Rappel Wetlands
Sans correction	0,386 ± 0,035	0,84	0,41	0,23	0,33	0,10
Poids de classe	0,440 ± 0,004	0,51	0,71	0,55	0,67	0,25
Suréchantillonnage	0,450 ± 0,012	0,78	0,53	0,37	0,47	0,25
SMOTE	0,367 ± 0,017	0,62	0,60	0,47	0,33	0,05

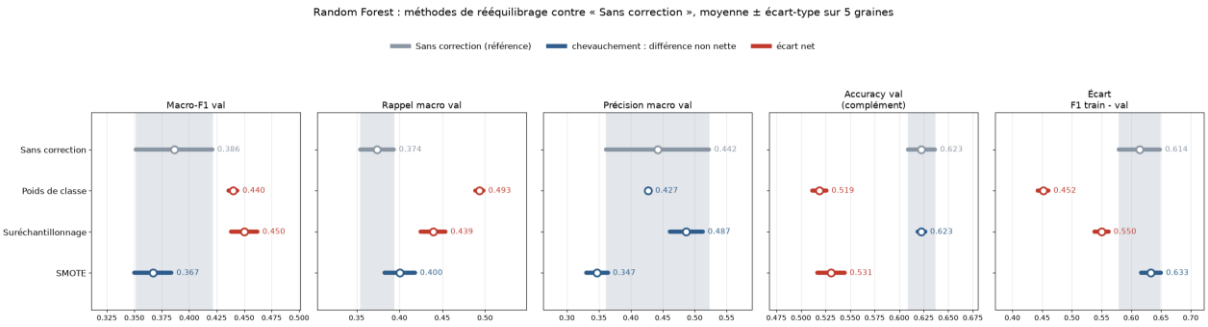


Figure : Random Forest : méthodes de rééquilibrage comparées à « sans correction »

Contrairement au réseau, la forêt aléatoire bénéficie nettement du rééquilibrage. Le suréchantillonnage obtient le meilleur Macro-F1 (0,450), devant les poids de classe (0,386). Il améliore la reconnaissance de plusieurs classes minoritaires tout en préservant relativement bien celle de Rubber (0,78). Les poids de classe dégradent davantage son rappel (0,51), tandis que SMOTE n'apporte aucun gain.

Le suréchantillonnage est donc retenu comme meilleur compromis. Toutefois, la forêt ayant tendance à très bien prédire ses données d'entraînement, la validation croisée reste nécessaire pour évaluer sa capacité de généralisation.

Résultat de la forêt obtenue

Modèle	Macro-F1	Rappel macro	Précision macro	MCC	Accuracy	Écart train − val	Temps (s)
ANN (référence)	0,389 ± 0,041	0,377 ± 0,023	0,469 ± 0,097	0,330 ± 0,025	0,645 ± 0,011	0,054 ± 0,034	35,2
Random Forest	0,450 ± 0,012	0,439 ± 0,014	0,487 ± 0,026	0,353 ± 0,013	0,623 ± 0,004	0,550 ± 0,012	5,4

La forêt dépasse nettement le réseau en Macro-F1 (0,450 contre 0,389) et en rappel macro (0,439 contre 0,377). Sa précision macro est un peu plus haute, mais les intervalles se chevauchent. Elle retrouve donc mieux les classes sans multiplier les fausses alertes. Son accuracy est en revanche nettement plus basse (0,623 contre 0,645), car elle prédit un peu moins souvent Rubber. Elle est aussi six fois plus rapide à entraîner.

Ce résultat rejoint la littérature : sur des données en tableau, les modèles à base d'arbres égalent ou dépassent souvent les réseaux de neurones (Grinsztajn et al., 2022).

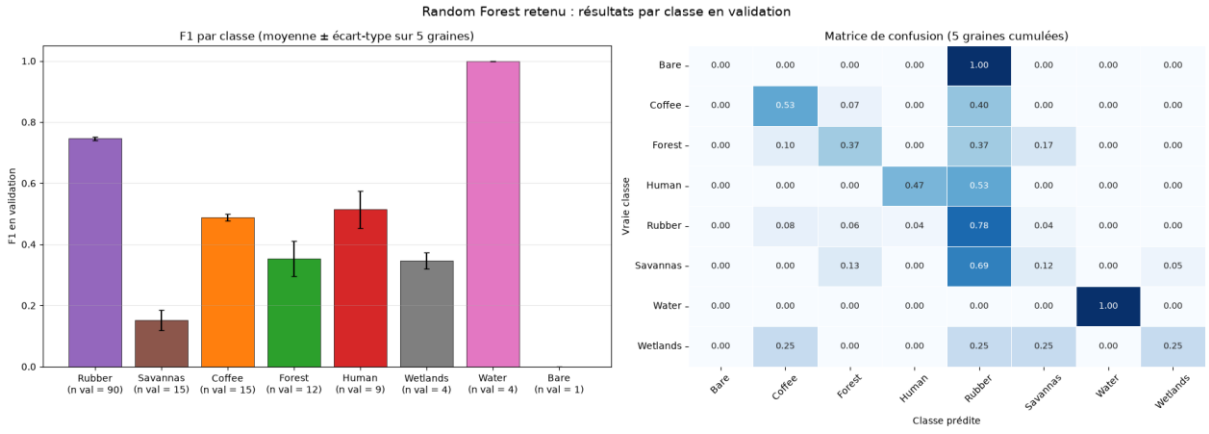
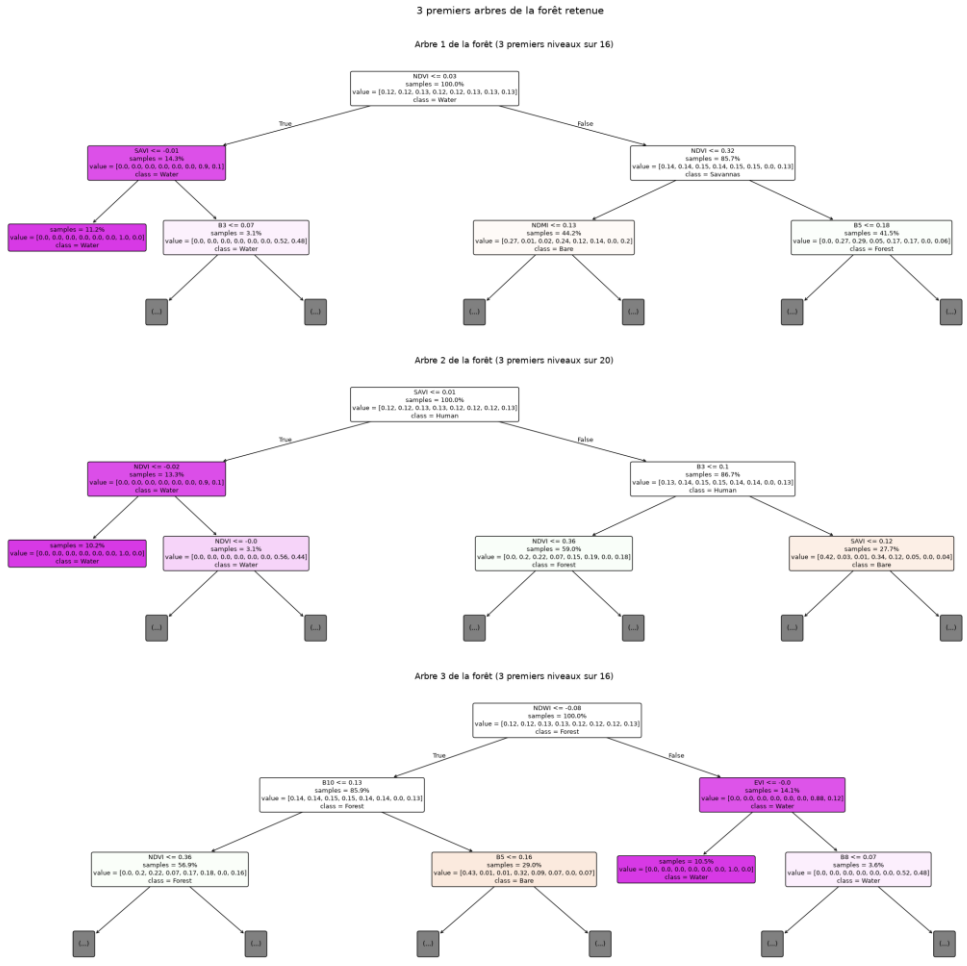


Figure : Random Forest retenu : F1 par classe (à gauche) et matrice de confusion normalisée (à droite), en validation

La matrice de confusion montre que les confusions avec Rubber persistent : 69 % des Savannas, 53 % des Human, 40 % des Coffee et 37 % des Forest sont classées Rubber. Bare Soil, avec une seule observation en validation, est toujours classée Rubber. Forest se partage entre Rubber, Savannas (17 %) et Coffee (10 %). Ce sont les mêmes confusions qu'avec le réseau : elles suivent la proximité des signatures spectrales vue au chapitre 1. La forêt les réduit, mais ne les supprime pas.

À quoi ressemblent les arbres ? La figure ci-dessous montre les trois premiers niveaux des trois premiers arbres. Chacun commence par une question différente (NDVI, SAVI ou NDWI) : le hasard rend bien les arbres différents. Mais tous isolent l'eau dès les premiers niveaux, ce qui confirme qu'elle est la classe la plus facile à séparer.



Validation croisée aléatoire et spatiale :

Nous avons ajouté une forêt sans correction à cette étape. Si le suréchantillonnage faisait surapprendre la forêt, son avantage devrait disparaître dans une zone nouvelle.

Modèle	Aléatoire	Spatiale	Perte
ANN (référence)	0,361 ± 0,033	0,288 ± 0,070	− 0,073
Random Forest sans correction	0,373 ± 0,071	0,251 ± 0,085	− 0,122
Random Forest suréchantillonné	0,416 ± 0,060	0,333 ± 0,104	− 0,083

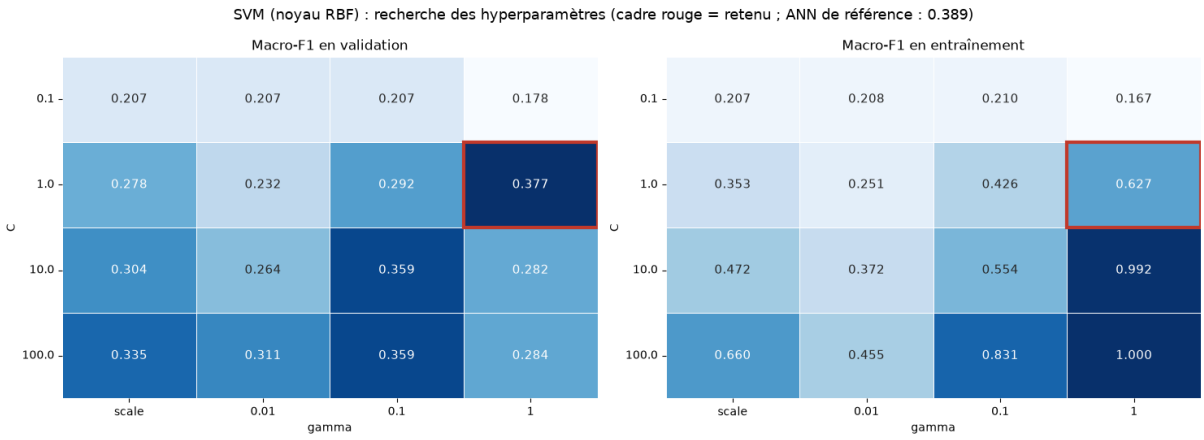
La forêt aléatoire avec suréchantillonnage obtient un meilleur Macro-F1 que le réseau en validation aléatoire (0,416 contre 0,389). Cet avantage se maintient en validation spatiale (0,333), malgré une baisse des performances. Le réseau présente toutefois une meilleure stabilité spatiale, avec une diminution de 0,073 contre 0,083 pour la forêt. Le chevauchement des intervalles ne permet cependant pas de conclure à une différence significative entre les deux modèles.

La configuration retenue pour Random Forest comprend 530 arbres, une profondeur maximale de 20, max_features = sqrt et min_samples_leaf = 1, avec suréchantillonnage. Son Macro-F1 atteint 0,450 en validation, puis 0,416 en validation croisée aléatoire et 0,333 en validation spatiale. Son avantage repose principalement sur le rééquilibrage des classes, puisque sans cette correction, son score (0,386) reste proche de celui du réseau (0,389).

2. SVM

Le SVM (Cortes et Vapnik, 1995) cherche à séparer les classes en maximisant la marge entre elles. Avec le noyau RBF (gaussien), il peut tracer des frontières non linéaires. Deux paramètres contrôlent son comportement : C, qui règle la tolérance aux erreurs, et gamma, qui détermine la complexité des frontières.

La grille croise 4 valeurs de C (0,1 ; 1 ; 10 ; 100) et 4 valeurs de gamma (scale ; 0,01 ; 0,1 ; 1), soit 16 combinaisons.



La combinaison retenue est C = 1 et gamma = 1, avec un Macro-F1 de 0,377 en validation et un écart train-validation de 0,250, indiquant un surapprentissage modéré. Les valeurs élevées de C et gamma entraînent un surapprentissage marqué, tandis qu'un C faible conduit à une mauvaise classification des autres classes au profit de Rubber.

Ce score reste toutefois isolé par rapport aux combinaisons voisines (0,28 à 0,29) et se situe à la limite de la grille testée. Sa stabilité devra donc être vérifiée par validation croisée.

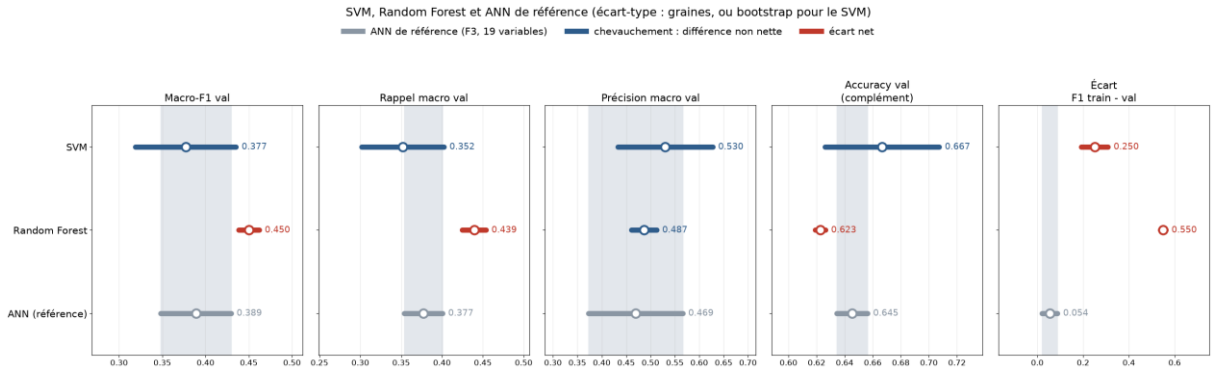
Choix du rééquilibrage

Méthode	Macro-F1	Rappel Rubber	Rappel Coffee	Rappel Forest	Rappel Human	Rappel Wetlands
Sans correction	0,377 ± 0,058	0,97	0,20	0,33	0,00	0,25
Poids de classe	0,364 ± 0,040	0,53	0,67	0,42	0,33	0,00
Suréchantillonnage	0,300 ± 0,040	0,70	0,56	0,08	0,11	0,00
SMOTE	0,335 ± 0,036	0,62	0,56	0,33	0,24	0,00

Aucune méthode de rééquilibrage n'améliore nettement le SVM, les intervalles se chevauchant avec celui du modèle sans correction, qui obtient la meilleure moyenne. Les poids de classe favorisent les classes minoritaires, mais pénalisent fortement Rubber, tandis que le suréchantillonnage et SMOTE dégradent certaines classes.

Le choix retenu est donc le SVM sans correction, qui offre le meilleur compromis global.

Résultat du SVM retenu



Le SVM ne se distingue pas nettement du réseau, leurs intervalles se chevauchant. Il reste inférieur à la forêt en Macro-F1 et en rappel macro, mais obtient la meilleure précision macro (0,530), accuracy (0,667) et rapidité d'exécution (0,2 s).

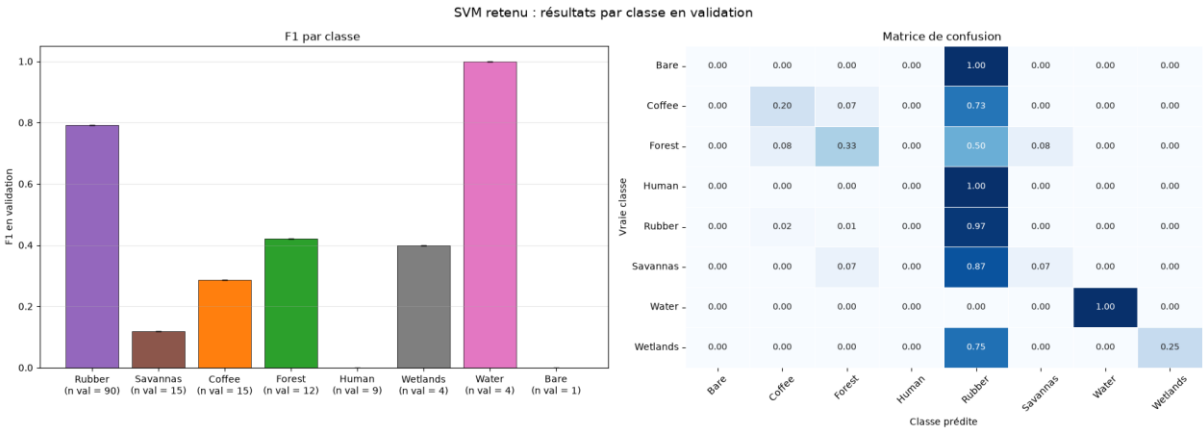


Figure : SVM retenu : F1 par classe (à gauche) et matrice de confusion normalisée (à droite), en validation

La matrice de confusion montre que le SVM privilégie fortement Rubber, au détriment des autres classes. Il reconnaît bien Water (F1 = 1,00) et Rubber (0,79), mais détecte difficilement les classes minoritaires. C'est un modèle prudent, qui prédit rarement une classe autre que Rubber, mais se trompe peu lorsqu'il le fait.

Validation croisée spatiale

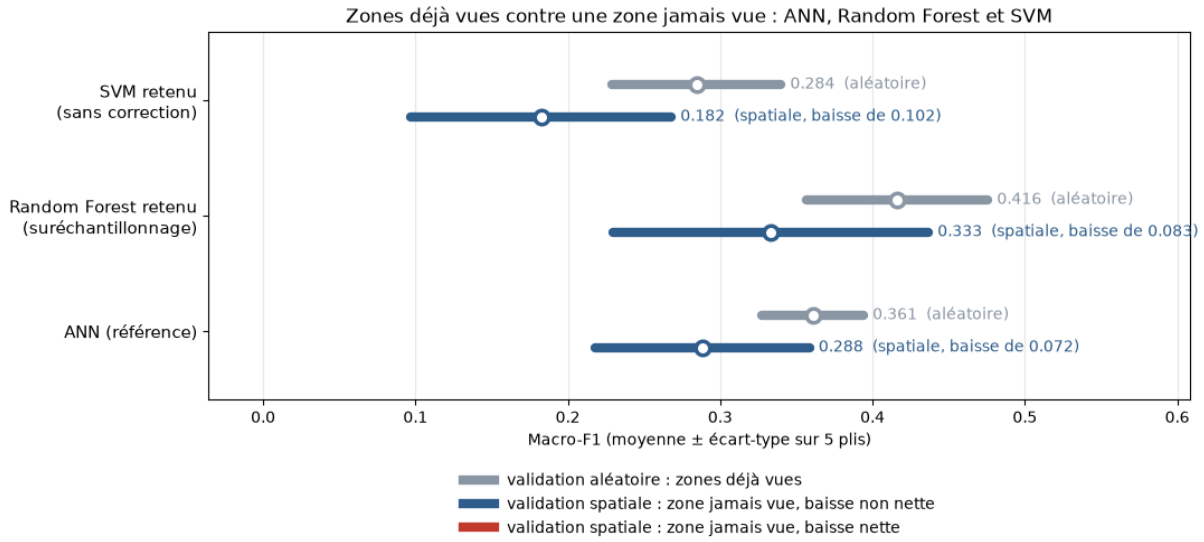


Figure : Macro-F1 dans des zones déjà vues (gris) et dans une zone jamais vue (bleu) pour les trois

Le SVM est le moins performant en validation croisée, avec un Macro-F1 de 0,284 en zones connues et 0,182 en zone nouvelle. Son score chute également de 0,377 à 0,284, confirmant que le meilleur résultat de la grille était en partie lié à la validation initiale.

La configuration retenue utilise un noyau RBF, C = 1, gamma = 1, sans rééquilibrage. Malgré une bonne précision et une bonne accuracy, ses performances restent fragiles et inférieures à celles de la forêt.

3. XGBoost

XGBoost (Chen et Guestrin, 2016) construit lui aussi des arbres, mais **les uns après les autres** : chaque nouvel arbre corrige les erreurs des précédents. C'est le boosting par gradient.

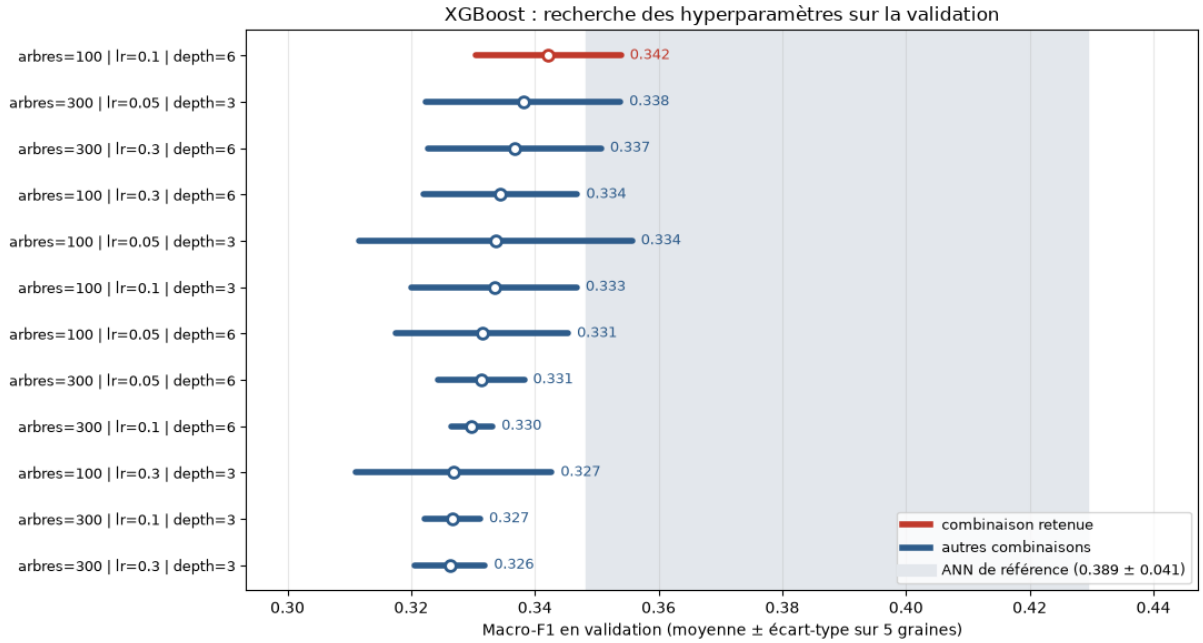


Figure : XGBoost : Macro-F1 en validation des 12 combinaisons (en rouge, la combinaison retenue)

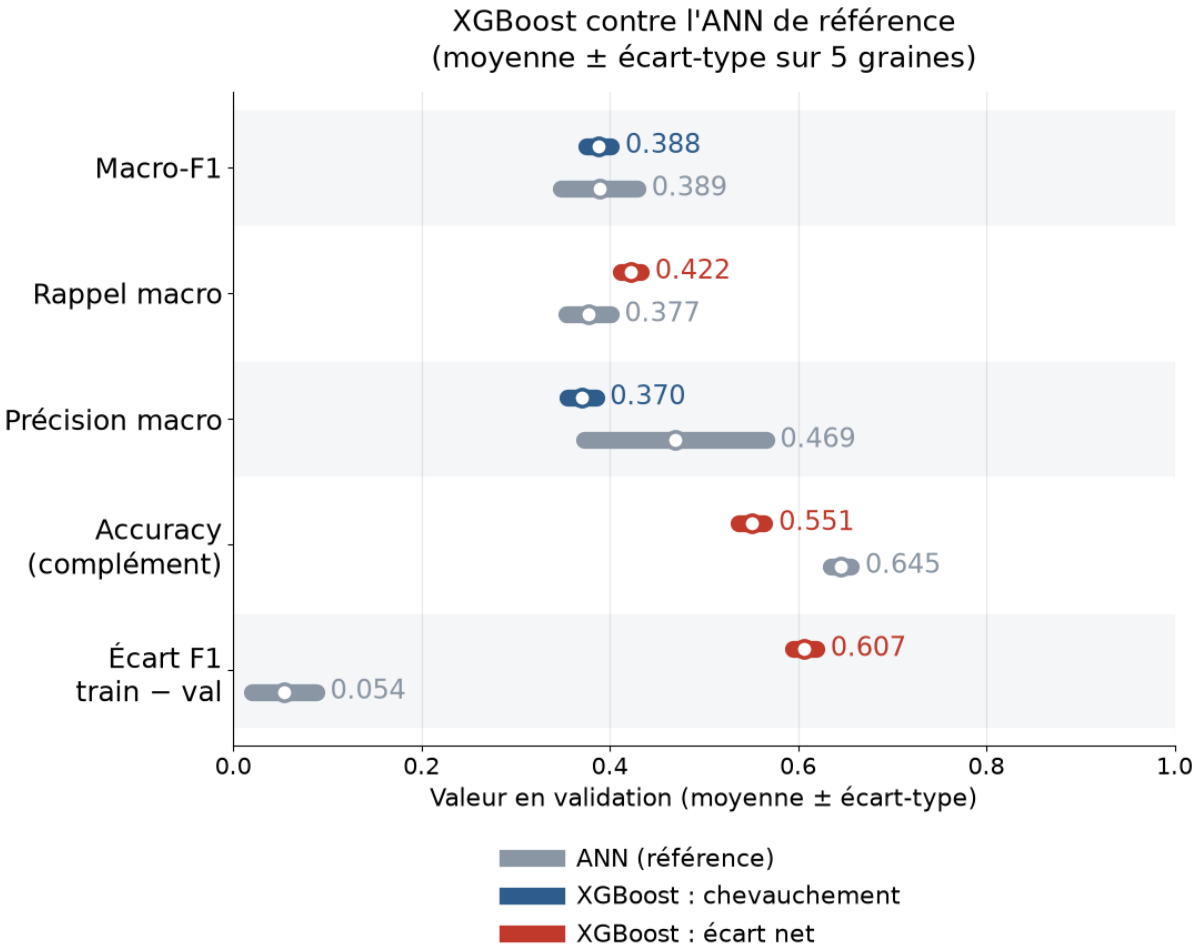
- **Retenu : 100 arbres, learning_rate = 0,1, max_depth = 6** (Macro-F1 de 0,342 ± 0,012).
- Les combinaisons se valent toutes (0,326 à 0,342) : le réglage compte peu.
- Sans rééquilibrage, XGBoost reste sous l'ANN en moyenne (0,342 contre 0,389).

Choix du rééquilibrage :

Méthode	Macro-F1	Rappel Rubber	Rappel Coffee	Rappel Forest	Rappel Human	Rappel Wetlands
Sans correction	0,342 ± 0,012	0,85	0,39	0,13	0,33	0,00
Poids de classe	0,376 ± 0,020	0,76	0,55	0,23	0,49	0,00
Suréchantillonnage	0,375 ± 0,006	0,76	0,53	0,18	0,51	0,00
SMOTE	0,388 ± 0,013	0,64	0,53	0,48	0,44	0,1

- **Les trois méthodes améliorent nettement le Macro-F1.** XGBoost profite du rééquilibrage, comme la forêt.
- **SMOTE donne la meilleure moyenne (0,388) : il est retenu.** Il améliore surtout Forest (0,13 → 0,48) ; Wetlands commence à être reconnue (0,10).
- Contrepartie : le rappel de Rubber passe de 0,85 à 0,64.

Résultats :



- **Macro-F1 au niveau de l'ANN** : 0,388 contre 0,389.
- **Rappel macro nettement meilleur** (0,422 contre 0,377) : il retrouve mieux les classes rares.
- **Accuracy nettement plus basse** (0,551 contre 0,645) : il prédit moins souvent Rubber.

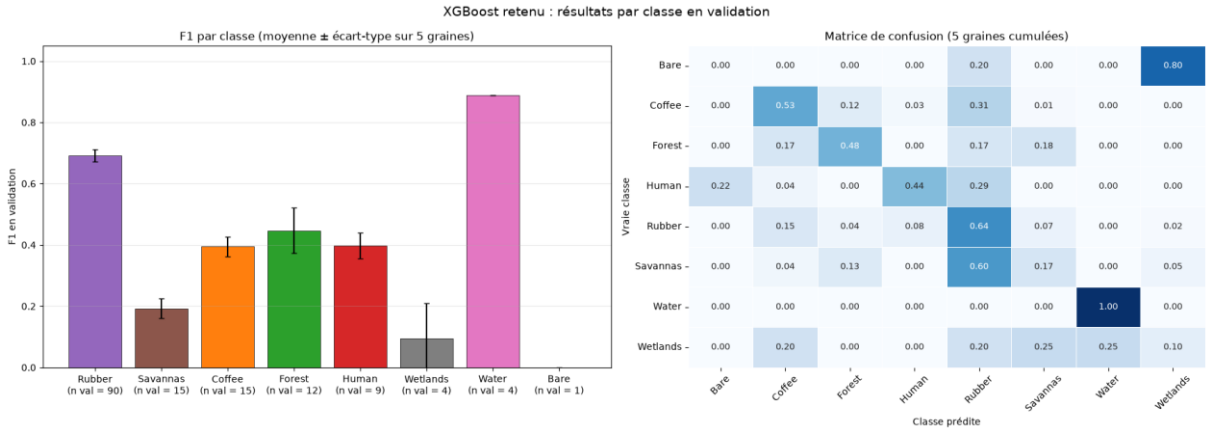


Figure : XGBoost retenu : F1 par classe et matrice de confusion normalisée (validation)

Validation croisée

Modèle	Aléatoire	Spatiale	Perte
ANN (référence)	0,361 ± 0,033	0,288 ± 0,070	− 0,073
XGBoost (SMOTE)	0,419 ± 0,053	0,317 ± 0,060	− 0,102

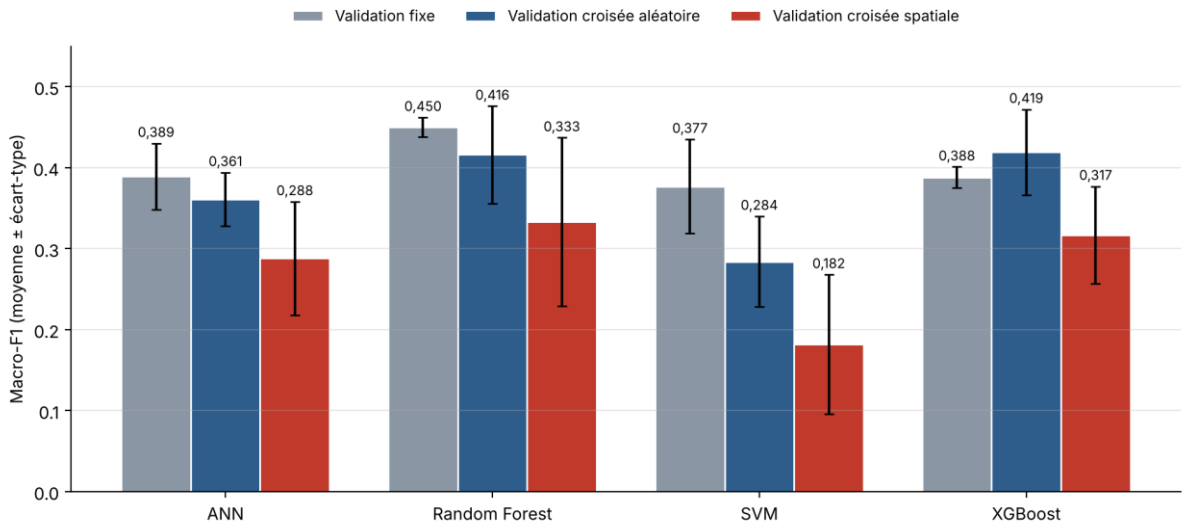
XGBoost conserve de meilleures performances moyennes que l'ANN dans les deux validations, malgré le chevauchement de leurs intervalles. Sa baisse en zone nouvelle est toutefois plus importante (0,102 contre 0,073), sans être statistiquement nette, ce qui montre que son écart train-validation élevé ne compromet pas nécessairement sa généralisation.

Comparaison des modèles

Modèle	**Rééquilibrage**	**Macro-F1**	**Rappel macro**	**Précision macro**	**Accuracy**	**Temps (s)**
ANN	Sans correction	0,389 ± 0,041	0,377 ± 0,023	0,469 ± 0,097	0,645 ± 0,011	35,2
Random Forest	Suréchantillonnage	0,450 ± 0,012	0,439 ± 0,014	0,487 ± 0,026	0,623 ± 0,004	3,4
SVM*	Sans correction	0,377 ± 0,058	0,352 ± 0,050	0,530 ± 0,097	0,667 ± 0,041	0,2
XGBoost	SMOTE	0,388 ± 0,013	0,422 ± 0,011	0,370 ± 0,015	0,551 ± 0,014	2,2

Random Forest est le seul modèle à dépasser nettement l'ANN en Macro-F1 (0,450), ainsi que XGBoost et le SVM. Avec XGBoost, il présente également un meilleur rappel, mais une accuracy plus faible. En revanche, les précisions ne montrent pas de différence nette entre les modèles.

Validation croisée :



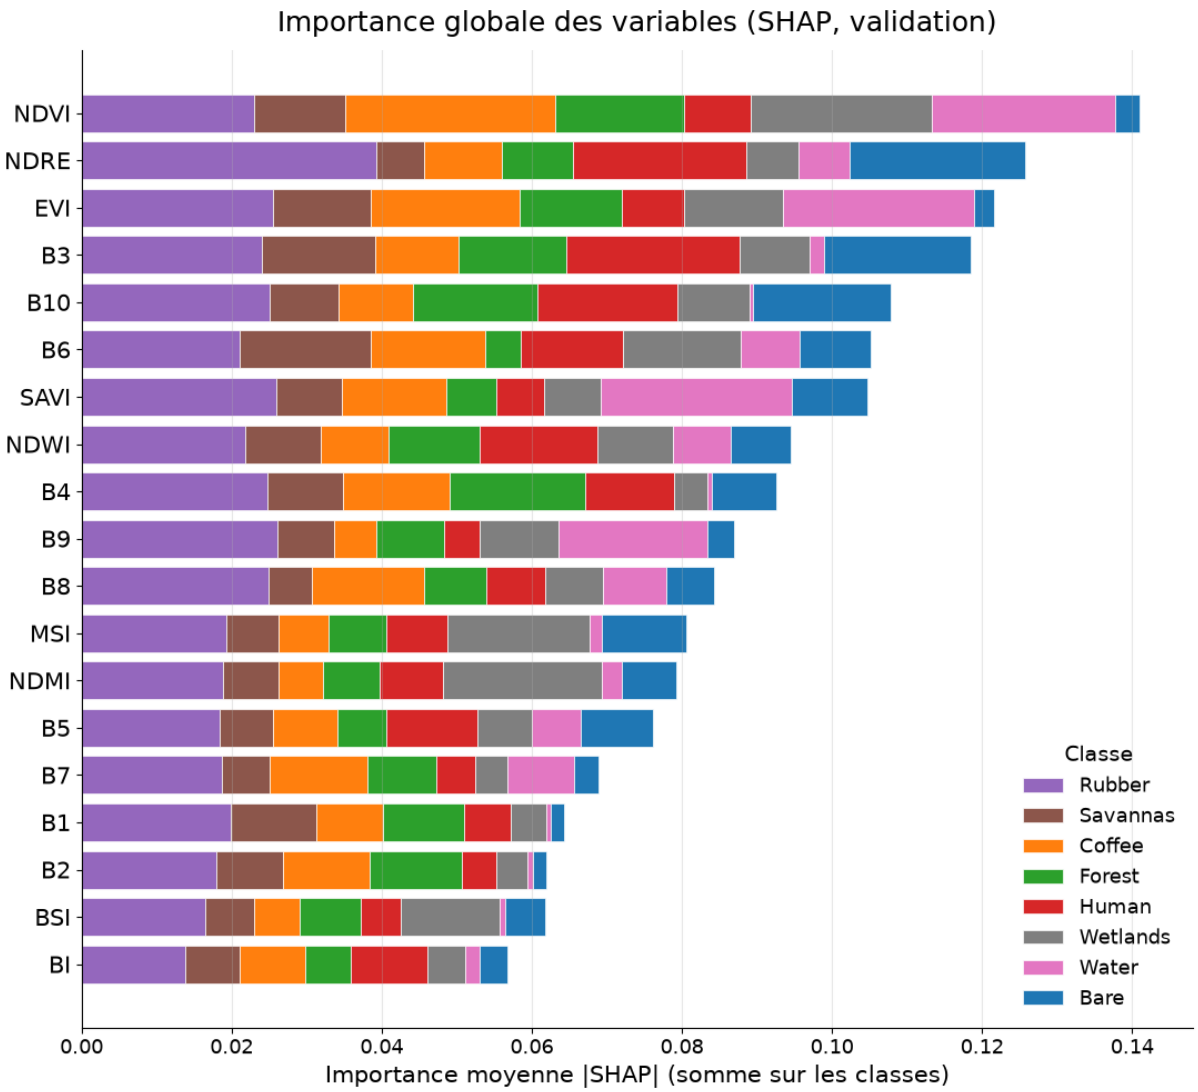
Random Forest n'est jamais nettement dépassé. XGBoost le devance légèrement en validation aléatoire (0,419 contre 0,416), sans différence significative. En zone nouvelle, aucun modèle ne se distingue clairement, tandis que l'ANN présente la meilleure stabilité spatiale. Le SVM reste le moins performant.

Random Forest est retenu comme modèle final, car il offre les meilleurs résultats globaux. L'ANN ne surpasse donc pas les méthodes classiques sur ces données tabulaires, comme le soulignent Grinsztajn et al. (2022). Cet avantage repose toutefois sur le rééquilibrage : sans correction, Random Forest (0,386) et XGBoost (0,342) ne dépassent pas l'ANN (0,389).

Modèle final : un pipeline associant standardisation, suréchantillonnage (uniquement à l'entraînement) et Random Forest, selon les paramètres de config_rf.json. Il retrouve le Macro-F1 obtenu en validation (0,450 ± 0,012).

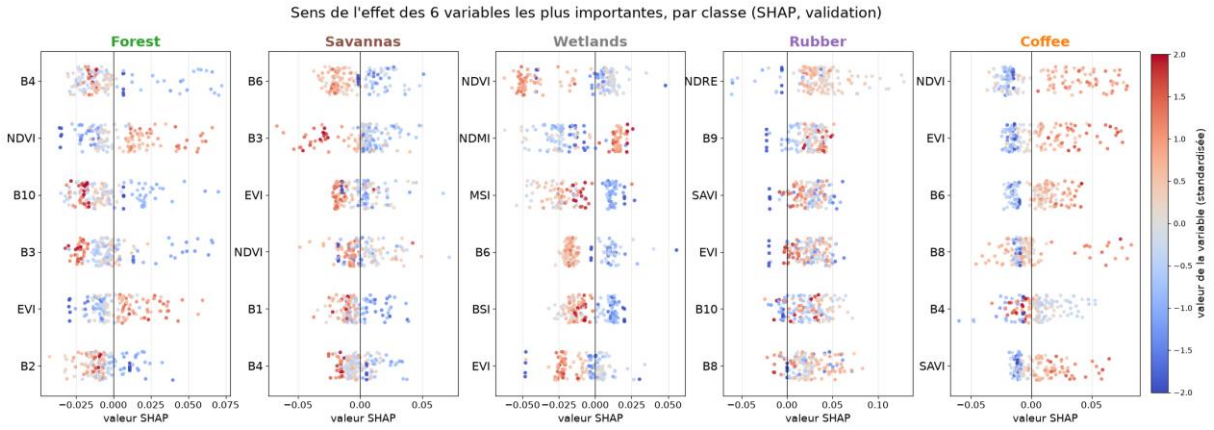
4. Quelles variables utilise-t-il ? (SHAP) ?

Principe : SHAP (Lundberg et Lee, 2017) mesure, pour chaque prédiction, la contribution de chaque variable : de combien elle pousse vers une classe ou l'en éloigne. La moyenne des valeurs absolues donne l'importance d'une variable.



Les indices de végétation sont les plus importants, notamment le NDVI (0,141), le NDRE (0,126) et l'EVI (0,122), suivis de B3, B10, B6 et SAVI. Les indices d'humidité et BI sont moins utilisés. Aucune variable ne domine réellement, et leur contribution sert principalement à distinguer la classe Rubber des autres classes.

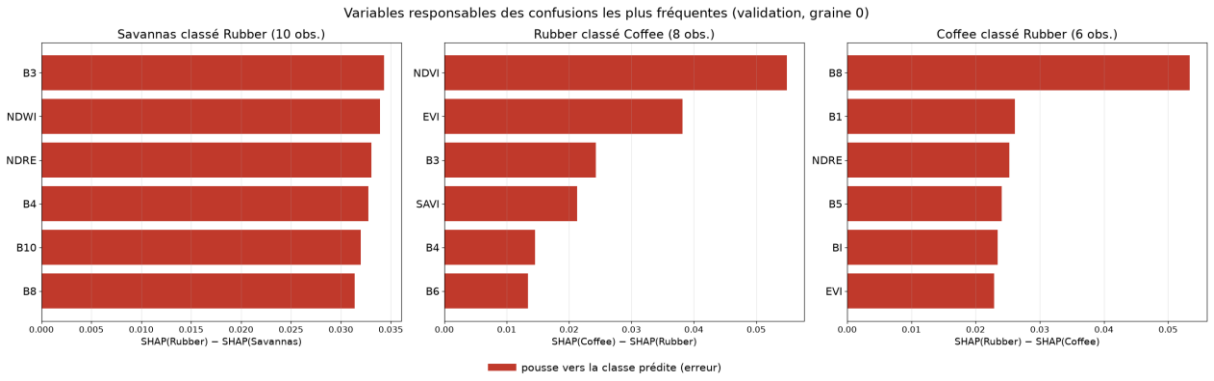
5. Dans quel sens agissent-elles ?



Forest se caractérise par des indices de végétation élevés et de faibles réflectances visibles, traduisant un couvert dense. Coffee présente un profil similaire, mais se distingue par des valeurs plus élevées de B6 et B8, ce qui explique certaines confusions entre les deux classes. Wetlands se distingue par un NDMI élevé et de faibles valeurs de MSI, BSI et NDVI. Rubber est favorisée par un NDRE élevé, tandis que Savannas présente des signaux peu marqués et dispersés, ce qui explique son faible rappel.

6. Analyse des erreurs

Avec la graine 0, la forêt fait 57 erreurs sur 150 en validation.



Les confusions concernent surtout les classes végétales. Les Savannas sont souvent classées en Rubber (10 cas) en raison de leur signature spectrale similaire. Les confusions entre Rubber et Coffee (8 et 6 cas) s'expliquent principalement par les indices de végétation NDVI et EVI, ainsi que par B8. Ces erreurs confirment la forte proximité spectrale entre les deux cultures arborées.

7. Evaluation finale sur l'ensemble de test

Le test (150 observations), jamais utilisé jusqu'ici, sert **une seule fois**. Il est standardisé par le pipeline avec les paramètres appris sur l'entraînement. Le Kappa est ajouté car l'énoncé le demande, malgré ses limites (Foody, 2020).

Ensemble	Macro-F1	Rappel macro	Précision macro	F1 pondéré	Kappa	MCC	Accuracy
Validation	0,450 ± 0,012	0,439 ± 0,014	0,487 ± 0,026	0,607 ± 0,006	0,351 ± 0,014	0,353 ± 0,013	0,623 ± 0,004
Test	0,309 ± 0,014	0,308 ± 0,023	0,356 ± 0,023	0,536 ± 0,008	0,225 ± 0,014	0,228 ± 0,014	0,563 ± 0,008

Toutes les métriques diminuent, avec un Macro-F1 passant de 0,450 à 0,309. L'accuracy baisse moins (0,623 à 0,563), car Rubber reste bien reconnue. Les valeurs de Kappa (0,225) et de MCC (0,228) traduisent un faible accord au-delà du hasard. Proche de la validation spatiale (0,333), ce résultat constitue une estimation plus réaliste des performances du modèle, le score initial étant optimiste en raison du réglage sur la validation.

Sauvegarde. Le pipeline final (graine 0), avec la liste des variables et les noms des classes, est enregistré dans resultats/modeles_finaux/random_forest_final.joblib

CONCLUSION FINALE

Ce projet avait pour objectif de classifier l'occupation du sol autour de Yamoussoukro en huit classes, à partir des bandes spectrales et des indices de télédétection, en comparant un réseau de neurones à trois méthodes classiques.

Les résultats montrent que Random Forest obtient les meilleures performances (Macro-F1 = 0,450 ± 0,012), devant l'ANN (0,389 ± 0,041), XGBoost (0,388) et le SVM (0,377). Ainsi, sur ces données tabulaires, le réseau de neurones ne surpasse pas les méthodes classiques. L'analyse SHAP révèle que la forêt s'appuie principalement sur les indices de végétation (NDVI, NDRE et EVI), tandis que ses principales erreurs résultent de la confusion entre classes végétales et de la prédominance de Rubber.

Enfin, sur le jeu de test, le modèle atteint un Macro-F1 de 0,309 ± 0,014 et une accuracy de 0,563. Il reconnaît correctement Rubber et Water, mais reste limité dans la classification des classes minoritaires. Ces résultats soulignent les difficultés liées au déséquilibre des classes et à la généralisation spatiale.

Le modèle final est consultable dans une application web de démonstration : https://occupation-sols-yakro.streamlit.app/

LIMITES

L'étude reste limitée par la taille du jeu de données (1 000 observations), le déséquilibre des classes, la faible représentation des classes rares et l'utilisation d'une seule date d'image. Certaines classes sont également concentrées dans des zones spécifiques.

Les modèles présentent un biais en faveur de Rubber, que le rééquilibrage ne corrige qu'au prix d'une baisse de ses performances. De plus, le réglage des modèles sur la validation a conduit à des scores optimistes, comme le montre la baisse du Macro-F1 de la forêt sur le test (0,450 à 0,309). Seule cette dernière a été évaluée sur le test, ce qui limite la comparaison finale.

Enfin, les ressemblances spectrales entre certaines classes compliquent leur distinction, tandis que la catégorie « Rubber and Other Crops » regroupe des cultures différentes. L'analyse SHAP permet d'identifier les variables utilisées par le modèle, mais ne renseigne pas sur les causes réelles de l'occupation du sol.

PERSPECTIVES

Les travaux futurs pourraient s’appuyer sur un échantillonnage plus équilibré, notamment pour les classes rares, et sur des séries temporelles d’images afin de mieux exploiter les variations saisonnières de la végétation. L’ajout de variables de texture et de contexte spatial pourrait également améliorer la distinction entre les classes et la généralisation des modèles.